

Tema 1.
Estadística
descriptiva
univariante.

Índice.

1. Introducción.
 - 1.1. La Estadística en el Ámbito de la Ciencia y la Ingeniería.
2. Definiciones básicas.
3. Tipos de datos.
4. Métodos gráficos y numéricos para describir datos cualitativos.
5. Métodos gráficos para datos cuantitativos.
6. Métodos numéricos para describir datos cuantitativos.
 - 6.1. Medidas de posición.
 - 6.2. Medidas de dispersión.
 - 6.3. Medidas de forma.
7. Métodos para detectar datos cuantitativos atípicos o fuera de rango.
 - 7.1. Mediante regla empírica.
 - 7.2. Mediante percentiles.

1. Introducción.

Según el Diccionario de la Real Academia Española de la Lengua, Estadística tiene tres acepciones, que relacionamos con algunos de los conceptos que veremos durante el tema.

1. *Estudio de los datos cuantitativos de la población, de los recursos naturales e industriales, del tráfico o de cualquier otra manifestación de las sociedades humanas.* → **Estadística Descriptiva** (Se utiliza para resumir, describir y explorar datos).
2. *Conjunto de estos datos.* → **Significado más común.**
3. *Rama de la matemática que utiliza grandes conjuntos de datos numéricos para obtener inferencias basadas en el cálculo de probabilidades* → **Inferencia estadística** (Utiliza los datos de un conjunto reducido de casos para inferir características de estos al conjunto de todos ellos).

1. La Estadística en el ámbito de la Ciencia y la Ingeniería.

El papel de la Estadística en la Ciencia y la Ingeniería es fundamental para analizar datos recopilados en experimentos de cualquier tipo, se observa en la mayoría de las ocasiones que dichos datos están sujetos a algún tipo de incertidumbre.

2. Definiciones básicas.

Población: Conjunto de individuos o casos, objetivo de interés. Dentro de la población podemos encontrar las poblaciones tangibles y conceptuales.

- Población tangible: Si la población consta de elementos físicos reales que forman un conjunto finito. **Ejemplo:** Si estamos considerando el estudio de la altura de los alumnos en la Escuela, el conjunto de estos alumnos.
- Población conceptual: La población no tiene elementos reales, sino que sus casos se obtienen por la repetición de un experimento. **Ejemplo:** En una prueba de placas de silicio, vemos que hay tantos casos como pruebas puedan hacerse, esto es un conjunto de datos infinitos.

Variable o dato: Es la característica concreta de una población. Siguiendo los ejemplos anteriores, en el primero podemos fijar la variable altura y en el segundo el espesor de la capa de óxido de silicio generada.

Muestra: Es el subconjunto de datos seleccionados de una población. El objetivo de esta es que los elementos de la muestra represente al conjunto de todos los elementos de la población. En esta asignatura sólo veremos un tipo de muestra, que son **muestras aleatorias simples**, esta se define como una muestra en la que todos los elementos de la población deben de tener las mismas posibilidades de salir en la muestra y, además, los elementos de la muestra deben ser independientes: el que salga un resultado en la muestra no debe afectar a que ningún otro resultado salga en la muestra.

3. Tipos de datos.

Los datos (o variables) pueden ser de dos tipos: **cuantitativos y cualitativos**.

- **Cuantitativos:** Son los que representan una cantidad reflejada en una escala numérica. A su vez, pueden clasificarse como **datos cuantitativos discretos** si se refieren al conteo de alguna característica, o **datos cuantitativos continuos** si se refieren a una medida.
- **Cualitativos:** Se refieren a características de la población que no pueden asociarse a cantidades con significado numérico, sino a características que sólo puedan clasificarse.

EJEMPLO:

- En el ejemplo del óxido de silicio, la variable espesor.
- En el ejemplo de los cojinetes, el diámetro de los cojinetes.
- En el ejemplo de los niveles de plomo, se está analizando si una muestra contiene niveles detectables o no.
- En el ejemplo de los accidentes laborales, la variable número de accidentes laborales.


4. Métodos gráficos y numéricos para describir datos cualitativos.

La forma más sencilla de describir de forma numérica una variable cualitativa es determinar su distribución de frecuencias.

Supongamos que tenemos una variable cualitativa, que toma una serie de posibles **valores** (categorías). El número de veces que se da cada valor es la **distribución de frecuencias** de la variable. Si en vez de dar el número de veces nos fijamos en la proporción de veces, tenemos la **distribución de frecuencias relativas**.

Las representaciones gráficas más usuales son:

- **Diagramas de barras:** Son una representación de cada una de las categorías de la variable mediante una barra colocada sobre el eje X y cuya altura sea la frecuencia o la frecuencia relativa de dichas categorías.
- **Diagramas de sectores:** Son círculos divididos en tantos sectores como categorías, sectores cuyo ángulo debe ser proporcional a la frecuencia de cada categoría.



4. Métodos gráficos y numéricos para describir datos cualitativos.

EJEMPLO:

Tomamos como población los 98 reactores nucleares más grandes en todo el mundo. Nos fijamos en la variable o dato referente al país donde están localizados.

Bélgica	Bélgica	Bélgica	Bélgica	Finlandia	Finlandia	Alemania	Alemania	Francia	Francia	Francia
				Francia	Francia	Francia				
Estados Unidos		Estados Unidos		Estados Unidos	Estados Unidos	Estados Unidos	Estados Unidos	Estados Unidos		
				Estados Unidos		Estados Unidos				
Estados Unidos		Estados Unidos		Estados Unidos	Estados Unidos	Estados Unidos	Estados Unidos	Estados Unidos		
				Estados Unidos		Estados Unidos				
Japón	Japón	Japón	Japón	Japón	Japón	Francia	Francia	Francia	Francia	Francia
				Francia	Francia	Suiza				
Estados Unidos		Estados Unidos		Estados Unidos	Estados Unidos	Estados Unidos	Japón	Japón	Suecia	Suecia
						Francia				
Estados Unidos		Estados Unidos		Estados Unidos	Estados Unidos	Estados Unidos	Estados Unidos	Estados Unidos		
				Estados Unidos		Estados Unidos				
Alemania	Alemania	Alemania	Alemania	Holanda	Japón	Alemania	Estados Unidos	Estados Unidos	Estados Unidos	Estados Unidos
Francia	Francia	Francia	Francia	Francia	Francia	Francia	Estados Unidos	Estados Unidos	Estados Unidos	Estados Unidos
Estados Unidos		Estados Unidos		Estados Unidos	Estados Unidos	Estados Unidos	Estados Unidos	Estados Unidos		
				Suecia	Estados Unidos	Francia				
Estados Unidos		Estados Unidos		Estados Unidos	Estados Unidos	Estados Unidos	Estados Unidos	Estados Unidos		
				Estados Unidos		Alemania				

Realiza una tabla de frecuencias y represente los datos mediante un diagrama de barras y uno de sectores.

5. Métodos gráficos para describir datos cuantitativos.

Una variable cuantitativa discreta con pocos valores, podemos tratarla como si fuera una variable cualitativa.

EJEMPLO: En una empresa con cadena de montaje donde se empaquetan piezas en cajas se realiza un estudio sobre la calidad de producción. Los datos siguientes informan sobre el número de piezas defectuosas encontradas en una muestra de cajas examinadas:

0 0 0 0 0 1 1 1 1 1 1 1 1 2 2 2 2 2 2 2 2 3 3
3 3 3 3 3 4 4 4 4 4 4 5 5 5 5 6 6 6 6 7 7 7 8 8 9

Aunque en la realidad, la mayoría de variables cuantitativas son de tipo continuo, de manera que toman demasiados valores como para que la representación de su distribución de frecuencias sea útil.

Un **histograma** es una variante del diagrama de barras donde se agrupan los valores de la variable en intervalos para que estos intervalos tienen frecuencias mayores que uno.

Para obtener un histograma de forma manual, hay que seguir los siguientes pasos:

1. Calculamos el número, **N**, de intervalos que vamos a utilizar. Se recomienda que sea aproximadamente igual a la raíz cuadrada del número de datos, aunque los programas estadísticos utilicen otro método.
2. Calculamos el rango, **R**, del histograma, que será ligeramente más amplio que el rango de los datos.
3. Calculamos la longitud, **L**, de los intervalos, como el cociente entre el rango del histograma y el número de intervalos.
4. Se construyen los **N** intervalos.
5. Para cada intervalo, contamos el número de datos que hay en él, es decir, la **frecuencia de intervalo**.
6. El histograma es un diagrama de barras donde en el eje X se colocan los intervalos y sobre ellos se construyen barras cuya altura sea la frecuencia o la frecuencia relativa del intervalo. En este caso, las barras deben dibujarse sin espacio entre ellas.

5. Métodos gráficos para describir datos cuantitativos.

EJEMPLO:

Los datos siguientes corresponden al tiempo necesario para procesar 25 trabajos en una CPU.

1.17	1.61	1.16	1.38	3.53	1.23	3.76	1.94	0.96	4.75
0.15	2.41	0.71	0.02	1.59	0.19	0.82	0.47	2.16	2.01
0.92	0.75	2.59	3.07	1.4					

Vamos a calcular un histograma con los siguientes datos.

6. Métodos numéricos para describir datos cuantitativos.

Medidas de posición (medidas de tendencia central): Son aquellas que tratan de establecer un valor que pueda considerarse el centro de los datos en algún sentido, responde a la pregunta **por dónde están los datos**.

- **Media:** Esta medida es la más común dentro de las de tendencia central y corresponde al **centro de gravedad** de los datos.

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

- **Mediana:** Es el valor de la variable que deja el mismo número de datos antes y después que él, una vez ordenados estos. Para calcular esto, tenemos que tener en cuenta varios aspectos:
 - Si **n** es **impar**, la mediana es el valor que ocupa la posición $(n + 1) / 2$, una vez que los datos han sido ordenados.
 - Si **n** es **par**, la mediana es la media aritmética de las dos observaciones centrales. Los dos datos que están en el centro de la muestra ocupan las posiciones $n/2$ y $n/2 + 1$.
- **Moda:** En principio la moda se define como el valor más frecuente de los datos. Lo que ocurre es que si éstos son datos de una variable continua o discreta con muchos valores, puede que los datos apenas se repitan. En ese caso se debe agrupar por intervalos, no debe darse un valor como moda, sino un **intervalo modal**, aquél con mayor frecuencia asociada.
- **Cuantiles:** Los cuantiles son medidas de posición pero no necesariamente ligadas al **centro** de los datos. El cuantil **p** de unos datos, sería el valor de la variables situado de modo que el 100p% de los valores sean menores o iguales que él y el resto $(100(1-p)\%)$.

6. Métodos numéricos para describir datos cuantitativos.

Medidas de posición (medidas de tendencia central):

- **Cuantiles:** Dentro de estos podemos referirnos a unos tipos de cuantiles que tienen otra forma de denominarse:
 - **Percentiles:** Son los cuantiles que dividen la muestra en 100 partes, es decir, son los cuantiles 0.01 (percentil 1), 0.02 (percentil 2), etc.
 - **Cuartiles:** Son aquellos que dividen la población en cuatro partes iguales, es decir, corresponden a los cuantiles 0.25, 0.5 (mediana) y 0.75.

EJEMPLO:

Considerando los datos del ejemplo anterior, los correspondientes al tiempo de procesamiento de 25 tareas en una CPU.

Calcula las distintas medidas de posición y coméntalas.

6. Métodos numéricos para describir datos cuantitativos.

Medidas de dispersión: Están relacionadas con las medidas de tendencia central, ya que lo que pretenden es cuantificar cómo de concentrados o dispersos están los datos respecto a estas medidas.

- **Varianza muestral:** Cuanto mayor sea la varianza de unos datos, más dispersos, heterogéneos o variables son esos datos. Cuanto más pequeña sea una varianza de unos datos, más agrupados u homogéneos son dichos datos.

$$s_{n-1}^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

- **Desviación típica o estándar muestral:** Esta se define como la raíz de la varianza muestral, esto hace que el análisis de la varianza sea posible, ya que la medida de la varianza son unidades al cuadrado, cosa que la desviación típica son unidades.

$$s_{n-1} = \sqrt{s_{n-1}^2}$$

- **Coeficiente de variación:** Una forma de valorar en términos relativos cómo es de dispersa una variable es precisamente proporcionar el cociente entre la desviación típica y la media (en valor absoluto).

$$CV = \frac{s_{n-1}}{|\bar{x}|}$$

EJEMPLO:

Considerando los datos del ejemplo anterior, los correspondientes al tiempo de procesamiento de 25 tareas en una CPU.

Calcula las distintas medidas de dispersión y coméntalas.

6. Métodos numéricos para describir datos cuantitativos.

Medidas de forma: Son aquellas que comparan la forma que tiene la representación gráfica, bien sea el histograma o el diagrama de barras de la distribución. La situación en la que los datos están repartidos de igual forma a uno y otro lado se conoce como **simetría**. Por contra, se dice que una distribución es **asimétrica a la derecha** si las frecuencias descienden más lentamente por la derecha que por la izquierda, en el caso contrario, diremos que la distribución es **asimétrica a la izquierda**.

Para valorar esto tenemos el el **coeficiente de asimetría de Fisher**.

$$As = \frac{\frac{\sum_{i=1}^n (x_i - \bar{x})^3}{n-1}}{s_{n-1}^3}$$

Parámetros muestrales y poblacionales: Cuando se trabaja con una muestra de una población, las distintas medidas de posición, dispersión y forma, se denominan **parámetros muestrales**. Frente a estos parámetros muestrales se encuentran parámetros análogos referidos a toda la población. Estos parámetros, llamados **parámetros poblacionales**, son imposibles de conocer.

EJEMPLO:

Considerando los datos del ejemplo anterior, los correspondientes al tiempo de procesado de 25 tareas en una CPU.

Calcula las distintas medidas de forma y coméntalas.

7. Métodos para detectar datos cuantitativos atípicos o fuera de rango.

Una observación que es inusualmente grande o pequeña en relación con los demás valores de un conjunto de datos se denomina **dato atípico o fuera de rango**.

Estos datos son atribuibles a los siguientes casos:

1. El valor ha sido introducido en la base de datos incorrectamente.
2. El valor proviene de una población distinta a la que estamos estudiando.
3. El valor es correcto pero representa un suceso muy poco común.

Hay dos formas de identificar estos datos:

- **Mediante la regla empírica:** Este método es adecuado si el histograma de los datos tiene forma de campana, en cuyo caso podemos aplicar la regla empírica para detectar qué datos están fuera de los rangos **lógicos** según esta regla.
- **Mediante los percentiles:** Supongamos que tenemos un conjunto de datos, el procedimiento es el siguiente:
 1. Se calculan los cuartiles primero y tercero, es decir, los percentiles 25 y 75. Se calcula el llamado **rango intercuartílico** que es la resta de los percentiles 75 y 25.
 2. Se consideran **datos atípicos** aquellos inferiores a $P_{25} - 1.5 \cdot RI$ o superiores a $P_{75} + 1.5 \cdot RI$

Hay una versión gráfica de este método para detectar valores atípicos mediante los percentiles, que se llama **diagrama de caja o diagrama de caja y bigotes (boxplot)**.

1. El valor de la mediana es el centro de la caja.
2. El valor de los percentiles 25 y 75 son los lados inferior y superior de la caja.
3. El diagrama no representa los límites, en su lugar, señala los últimos puntos no atípicos por debajo y por encima y los representa como **bigotes** que salen de la caja.
4. Normalmente representa con círculos los datos atípicos.