

Práctica 6. Modelo Regresión Lineal Simple.

Objetivos

1. Estimar los parámetros del modelo de regresión lineal simple (MRLS).
2. Realizar la inferencia respecto de los parámetros del modelo.
3. Obtener predicciones en base al modelo ajustado.
4. Interpretar convenientemente los resultados.
5. Validar el modelo ajustado mediante procedimientos gráficos y analíticos.

Estimación del MRLS

La función `lm` en la librería `stats` (**R** base) permite realizar la estimación de modelos.

La sintaxis básica para estimar MRLS es la siguiente:

```
modelo <- lm(formula = variable_dependiente ~ variable_independiente, data = datos)
```

Los principales argumentos son:

formula: es la fórmula que relaciona la variable dependiente (que queremos predecir) con la variable independiente.

datos: datos es un dataframe que contiene las variables.

La función `lm()` devuelve un objeto de la clase `lm`, algunas propiedades son:

- **coefficients** → Contiene los coeficientes estimados del modelo.
- **residuals** → Vector con los residuos (errores) entre los valores reales y los ajustados.
- **fitted.values** → Valores predichos por el modelo.
- **df.residual** → Grados de libertad de los residuos.
- **residuals** → Contiene los residuos de la regresión.

Métodos para acceder al objeto `lm`:

Una vez hemos ajustado el modelo de regresión mediante la función `lm` podremos acceder a las diferentes salidas haciendo uso de los siguientes métodos:

- **Resumen del modelo (`summary`):** Muestra un resumen del análisis, con errores estándar, valores t, p-valores, medidas de ajuste, etc.
- **Coefficientes del modelo (`coefficients`):** Devuelve los valores estimados de los coeficientes de regresión.
- **Valores ajustados (`fitted.values`):** Devuelve las predicciones generadas por el modelo para los datos de la variable independiente.
- **Residuos (`residuals`):** Devuelve las diferencias entre los valores observados y los predichos por el modelo.
- **Residuos estandar (`rstandard`):** Devuelve las diferencias tipificadas, entre los valores observados y los predichos por el modelo.
- **Intervalos de confianza (`confint`):** Construye intervalos de confianza para los coeficientes.
- **Predicciones (`predict`):** Devuelve las predicciones puntuales o intervalos de confianza para las predicciones.


El funcionamiento de cada uno de estos métodos está disponible en la ayuda.

Ejemplo

El fichero software.Rdata contiene los datos de las líneas de código y duración de 9 proyectos que se han desarrollado en una determinada empresa.

```
# Leemos los datos
load("datos6/software.Rdata")

# Representamos los datos para ver la posible relación lineal de los mismos
plot/software$LC,software$Horas)
```



```
# Estimamos el modelo
modelo <- lm(Horas ~ LC, data = software)

# Mostramos el resumen del modelo
summary(modelo)
```

```
##
## Call:
## lm(formula = Horas ~ LC, data = software)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -43.004 -13.414   9.069  14.882  36.339
##
## Coefficients:
```

```
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept) 73.927222  18.236129   4.054  0.00485 **
## LC          0.027884   0.002733  10.204 1.87e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 27.23 on 7 degrees of freedom
## Multiple R-squared:  0.937, Adjusted R-squared:  0.928
## F-statistic: 104.1 on 1 and 7 DF, p-value: 1.872e-05

# Mostramos los coeficientes
coeficients(modelo) # Horas = 53.67932281 + 0.03531722 *LC

## (Intercept)          LC
## 73.92722199  0.02788419

coef(modelo) # Horas = 53.67932281 + 0.03531722 *LC

## (Intercept)          LC
## 73.92722199  0.02788419

# Construimos los intervalos de confianza al 90% de confianza
confint(modelo, level = 0.9)

##               5 %           95 %
## (Intercept) 39.37744131 108.47700267
## LC          0.02270699  0.03306139

# Mostramos los valores estimados
fitted.values(modelo)

##           1           2           3           4           5           6           7           8
## 94.00384 140.43103 179.30159 186.43995 215.16067 265.15703 303.41414 335.11847
##           9
## 398.97328

# Mostramos los errores o residuos (son la diferencia entre el verdadero valor de Y y
# el valor de Y estimado mediante el modelo)
residuals(modelo)

##           1           2           3           4           5           6           7
## -43.00384  9.068974 -8.301593 22.560053 36.339332 10.842971 -13.414144
##           8           9
## 14.881527 -28.973278

# Predecimos la duración de dos programas con 20000 y 30000 líneas de código,
# respectivamente
nuevos.datos = data.frame(LC = c(20000, 30000))
predict(modelo, nuevos.datos)

##           1           2
## 631.6111 910.4531

# Construimos un intervalo de confianza para la duración media de dos programas con 20000
# y 30000 líneas de código, respectivamente
predict(modelo, nuevos.datos, interval = "confidence")

##           fit          lwr          upr
## 1 631.6111 537.3068 725.9154
## 2 910.4531 752.5412 1068.3649
```

```
# Construimos un intervalo de confianza para la duración de dos programas con 20000 y 30000  
# líneas de código, respectivamente  
predict(modelo, nuevos.datos, interval = c("prediction"), level = 0.99)
```

```
##          fit          lwr          upr  
## 1 631.6111 462.6285 800.5938  
## 2 910.4531 658.0800 1162.8261
```


Diagnosis del MRLS por métodos gráficos y analíticos

El MRLS se basa en una serie de hipótesis que debemos comprobar. Si estas hipótesis no se cumplen, las conclusiones que se obtienen del modelo, no son fiables. Por tanto, la diagnosis del modelo es crucial.

La diagnosis se realiza mediante métodos gráficos (subjetivos) y analíticos (objetivos). Los gráficos nos pueden orientar sobre si se cumplen o no las hipótesis del modelo, no obstante, para tener certeza, necesitamos los métodos analíticos (contrastes de hipótesis)


Métodos gráficos

```
#capturamos los residuos  
  
residuos <- residuals(modelo)  
residuos.estandarizados <- rstandard(modelo)  
valores.estimados <- fitted.values(modelo)  
  
#Gráfico de residuos (Buscamos patrones)  
  
plot(residuos)  
abline(h = 0, col = "red", lwd = 2)
```



#Gráfico valores ajustados frente a valores estandarizados (Buscamos patrones)

```
plot(valores.estimados, residuos.estandarizados)  
abline(h = 0, col = "red", lwd = 2)
```




```
##QQplot
```

```
library(car)
```

```
## Loading required package: carData
```


```
qqPlot(modelo$residuals) #Gráfico cuantil-cuantil
```



```
## [1] 1 5
```

```
##Nube de puntos junto a la recta de regresión (muestra cómo de bueno es el ajuste)
plot(software$LC, software$Horas, main="Regresión Lineal Simple",
     xlab="Variable Independiente", ylab="Variable Dependiente",
     pch=19, col="blue")
abline(modelo, col="red", lwd=2)
```

Regresión Lineal Simple



Métodos analíticos

```
#Normalidad de los residuos
```

```
shapiro.test(residuos)
```

```
##
```

```
## Shapiro-Wilk normality test
```

```
##
```

```
## data:  residuos
```

```
## W = 0.96738, p-value = 0.8714
```

```
#shapiro.test(residuals(modelo))
```

```
#Homocedasticidad de los residuos
```

```
library(lmtest)
```

```
## Loading required package: zoo
```

```
##
```

```
## Attaching package: 'zoo'
```

```
## The following objects are masked from 'package:base':
```

```
##
```

```
## as.Date, as.Date.numeric
```

```
bptest(modelo)
```

```
##
```

```
## studentized Breusch-Pagan test
```



```
##
## data:  modelo
## BP = 0.80183, df = 1, p-value = 0.3705
#Ausencia de autocorrelación
dwtest(modelo,alternative = "two.sided")

##
## Durbin-Watson test
##
## data:  modelo
## DW = 1.5646, p-value = 0.2377
## alternative hypothesis: true autocorrelation is not 0
```

EJERCICIO

El fichero `Compilacion.RData` contiene los datos acerca del tiempo que un compilador de LaTeX tarda en compilar 100 archivos (en segundos) junto con su tamaño (en KB). Al 1% de significación:

1. Analice si los tamaños de compilación han sido extraídos aleatoriamente.
2. Represente gráficamente los datos de forma conjunta. A la vista del gráfico, ¿cree que existe relación lineal entre el tiempo de compilación de un archivo y su tamaño? ¿Sería apropiado estimar un modelo de regresión de tipo lineal?
3. Cuantifique el grado de asociación lineal entre las variables.
4. Estime un modelo de regresión lineal para explicar el tiempo que un archivo LaTeX tarda en ser compilado a partir de su tamaño. ¿Qué sucede con el tiempo de compilación a medida que aumenta el tamaño del archivo?
5. ¿Es el tamaño de un archivo relevante para explicar el tiempo que tarda en ser compilado?
6. ¿Existe evidencia para afirmar que la ordenada en el origen es nula?
7. Realice la diagnosis del modelo ajustado.
8. Pronostique el tiempo que un archivo LaTeX de 25 KB tarda en ser compilado con una confianza del 99%.
9. Analice si la predicción realizada en el apartado anterior es fiable.