

Práctica 3. Estadística descriptiva univariante

Objetivos

1. Resumir los datos en tablas
2. Construir gráficos descriptivos
3. Calcular medidas de posición, dispersión y forma
4. Detectar datos atípicos
5. Interpretar los resultados
6. Realizar estudio estadístico por grupos

Resumir los datos en tablas

Vamos a diferenciar entre datos cualitativos y datos cuantitativos, y dentro de los cuantitativos entre discretos y continuos.

Datos cualitativos

Para la creación de las tablas de frecuencias utilizaremos la función `table` para calcular las frecuencias absolutas y la función `prop.table` para calcular las frecuencias relativas.

Ejemplo

#Se dispone de un vector de SS00

```
SS00 <- c("MacOS", "Windows", "Linux", "MacOS", "Windows",  
          "MacOS", "Linux", "Windows", "Windows", "MacOS")  
tabla_SS00_A <- table(SS00)  
print(tabla_SS00_A)
```

```
## SS00  
##   Linux   MacOS Windows  
##      2      4      4
```

```
tabla_SS00_R <- prop.table(tabla_SS00_A)  
print(tabla_SS00_R)
```

```
## SS00  
##   Linux   MacOS Windows  
##   0.2    0.4    0.4
```

#Esto se podría mejorar generando un dataframe con la información anterior

```
tablaFreq <- data.frame(SS00 = names(tabla_SS00_A),  
                        ni = as.vector(tabla_SS00_A),  
                        fi = as.vector(tabla_SS00_R))  
tablaFreq
```

```
##      SS00 ni  fi
## 1   Linux  2 0.2
## 2   MacOS  4 0.4
## 3 Windows  4 0.4
```

Datos cuantitativos discretos

Para generar la tabla de frecuencias de datos discretos usaremos las mismas funciones que en el caso cualitativo, esto es, `table` y `prop.table`.

Veamos un ejemplo

```
# La siguiente variable almacena los días que ha faltado al trabajo un programador
faltas <- c(3, 7, 2, 4, 5, 3, 2, 5, 4, 3)
```

```
frec_absoluta <- table(faltas)
print(frec_absoluta)
```

```
## faltas
## 2 3 4 5 7
## 2 3 2 2 1
```

```
frec_relativa <- prop.table(frec_absoluta)
print(frec_relativa)
```

```
## faltas
##  2  3  4  5  7
## 0.2 0.3 0.2 0.2 0.1
```

```
#Al igual que en el apartado anterior sería posible generar una tabla de frecuencias
#más completa
```

```
tablaFreqDiscreta <- data.frame(
  faltas = names(frec_absoluta),
  ni = as.vector(frec_absoluta),
  Ni = cumsum(as.vector(frec_absoluta)),
  fi = as.vector(frec_relativa),
  Fi = cumsum(as.vector(frec_relativa))
)
```

```
tablaFreqDiscreta
```

```
##  faltas ni Ni  fi  Fi
## 1      2  2  2 0.2 0.2
## 2      3  3  5 0.3 0.5
## 3      4  2  7 0.2 0.7
## 4      5  2  9 0.2 0.9
## 5      7  1 10 0.1 1.0
```

Datos cuantitativos continuos

En el caso de disponer de datos continuos, o datos discretos que toman muchos valores diferentes, estos se agrupan en intervalos para construir la tabla de frecuencias. Por tanto, lo primero que debemos hacer es establecer los intervalos (clases) y a continuación calcular las frecuencias de cada intervalo.

Para poder hacer esto en R, además de las funciones `table` y `prop.table` haremos uso de la función `cut`. Por defecto, los intervalos se construyen de la forma `(,]`.

Ejemplo

*#La variable procesos contiene el número de procesos concurrentes en un servidor
#en diferentes instantes de tiempo*

```
procesos <- c(160, 165, 170, 175, 180, 160, 165, 170, 175, 180,  
             185, 190, 195, 160, 165, 170, 175, 180, 185, 190)
```

#Definimos los intervalos

```
intervalos <- cut(procesos, breaks = seq(150, 200, by = 10), right = TRUE)
```

```
frec_absoluta <- table(intervalos)
```

```
frec_relativa <- prop.table(frec_absoluta)
```

```
tablaFreq <- data.frame(  
  intervalos = names(frec_absoluta),  
  ni = as.vector(frec_absoluta),  
  Ni = cumsum(as.vector(frec_absoluta)),  
  fi = as.vector(frec_relativa),  
  Fi = cumsum(as.vector(frec_relativa))  
)  
tablaFreq
```

```
##   intervalos ni  Ni   fi   Fi  
## 1  (150,160]  3   3 0.15 0.15  
## 2  (160,170]  6   9 0.30 0.45  
## 3  (170,180]  6  15 0.30 0.75  
## 4  (180,190]  4  19 0.20 0.95  
## 5  (190,200]  1  20 0.05 1.00
```

Representación gráfica de los datos

R dispone de librerías que permiten la creación de gráficos avanzados, no obstante, nosotros nos vamos a centrar en los gráficos disponibles en R base. A continuación presentamos los más importantes.


Gráfico de barras

El gráfico de barras se emplea para representar la frecuencia (absoluta o relativa) de cada categoría en variables cualitativas. La función para su creación es `barplot`.

Ejemplo

```
SS00 <- c("MacOS", "Windows", "Linux", "MacOS", "Windows",  
         "MacOS", "Linux", "Windows", "Windows", "MacOS")  
tabla_SS00_A <- table(SS00)  
barplot(tabla_SS00_A, main = "Gráfico Barras SS00",  
        xlab = "Sistema Operativo", ylab = "Frecuencia absoluta",  
        col = c("red", "blue", "green"))
```

Gráfico Barras SS00



```
tabla_SS00_R <- prop.table(tabla_SS00_A)
barplot(tabla_SS00_R, main = "Gráfico Barras SS00",
        xlab = "Sistema Operativo", ylab="Frecuencia relativa",
        col = c("red", "blue", "green"))
```





Gráfico de sectores

Para representar el diagrama de sectores en R se utiliza la función `pie`

```
# Gráfico de sectores (pastel)
pie(tabla_SS00_A, main = "Gráfico de Sectores Uso SS00",
    col = c("red", "blue", "green"))
```


Gráfico de Sectores Uso SS00



*#Si deseamos que el gráfico muestre la frecuencia de cada sector
#modificamos las etiquetas y las incluimos en el argumento labels*

```
etiquetas = paste(names(tabla_SS00_A), tabla_SS00_A, sep=": ")  
pie(tabla_SS00_A, main = "Gráfico de Sectores Uso SS00",  
    col = c("red", "blue", "green"),  
    labels = etiquetas)
```


Gráfico de Sectores Uso SS00



#También es posible incluir una leyenda con la función `legend`

```
pie(tabla_SS00_A, main = "Gráfico de Sectores Uso SS00",  
    col = c("red", "blue", "green"), labels = tabla_SS00_A)  
legend("topright",  
       c("Linux", "MacOS", "Windows"),  
       cex = 0.8,  
       fill = c("red", "blue", "green"))
```

Gráfico de Sectores Uso SSOO



Histograma


Es el gráfico más utilizado a la hora de representar datos continuos o agrupados en intervalos. La función `hist` es la encargada de generar el histograma. Por defecto, esta función emplea el método de “Sturges” para establecer los intervalos. Otros métodos posibles son el de “Scott” y el de “Freedman-Diaconis”. No obstante, podemos cambiar los intervalos utilizando el parámetro `breaks` de la función con los extremos deseados. Por defecto, los intervalos se establecen de la forma `(, ]`.

Ejemplo

#Volviendo al ejemplo de los procesos concurrentes

```
hist(procesos , main = "Histograma para procesos concurrentes",  
      xlab = "Número de procesos",  
      ylab = "Frecuencia",  
      col = "red")
```



Histograma para procesos concurrentes



*#Este histograma no se adapta a los intervalos que hemos definido, para aplicar nuestros
#intervalos*

```
hist(procesos , breaks = seq(150, 200, by=10),  
      main = "Histograma para procesos concurrentes",  
      xlab = "Número de procesos",  
      ylab = "Frecuencia",  
      col = "red")
```

Histograma para procesos concurrentes




Polígono de frecuencias

Es la curva que une los puntos medios altos de cada rectángulo del histograma. Para su representación hay que calcular los puntos medios y asignarle la frecuencia que tiene el intervalo al que representan. La función que se usa para su representación de plot.

```
#Definimos los intervalos
intervalos <- cut(procesos, breaks = seq(150, 200, by = 10), right = TRUE)
puntosMedios <- seq(155, 200, by=10)
frec_absoluta <- table(intervalos)

plot(puntosMedios, as.numeric(frec_absoluta), type = "o",
     main = "Polígono de Frecuencias",
     xlab = "Valor", ylab = "Frecuencia",
     ylim = c(0, max(frec_absoluta) + 1))
```

Polígono de Frecuencias




Curva acumulativa

Consiste en representar gráficamente la función $F(x)$ definida como “nº de individuos o elementos de la población que presentan un valor menor o igual que $x \in R$ ”. En el caso de variable continua, esta función es continua, ya que son posibles todos los valores situados entre dos puntos y se supone que la distribución de éstos en cada intervalo es proporcional. Por tanto usaremos los extremos de los intervalos y consideramos que al final del intervalo se alcanza la frecuencia acumulada.

```
frecAcumulada=c(0,cumsum(frec_absoluta))
extremos=seq(150, 200, by = 10)

plot(extremos, as.numeric(frecAcumulada), type = "o",
      main = "Curva Acumulativa",
      xlab = "Valor", ylab = "Frecuencia Acumulativa",
      ylim = c(0, max(frecAcumulada) + 1))
```



Medidas de posición, dispersión y forma

Medidas de posición central

Las principales medidas de posición son: la media (`mean`), la mediana (`median`) y la moda (no existe una función para su cálculo en *R base*). Veamos con un ejemplo cómo se usan estas funciones.

Ejemplo

```
# La siguiente variable contiene los días que ha faltado al trabajo un programador en el
# último semestre
faltas <- c(3, 7, 2, 4, 5, 3, 2, 5, 4, 30, 22)
```

```
# Calculamos la media
media <- mean(faltas)
print(media)
```

```
## [1] 7.909091
```

```
# Calculamos la mediana
mediana <- median(faltas)
print(mediana)
```

```
## [1] 4
```

```
# Para el cálculo de la moda podemos utilizar la función 'Mode' del paquete 'DescTools' o
# bien construir la tabla de frecuencias y buscar la categoría, el valor o el intervalo
 #(según corresponda) con mayor frecuencia absoluta.
```

```
#Paquete DescTools
#install.packages("DescTools", repos = "https://cran.rediris.es/")
library("DescTools")
```

```
## Warning: package 'DescTools' was built under R version 4.4.3
```

```
Mode(faltas)
```

```
## [1] 2 3 4 5
## attr("freq")
## [1] 2
```

```
#R base
frecFaltas <- table(faltas)
Moda <- names(frecFaltas[frecFaltas == max(frecFaltas)])
print(Moda)
```

```
## [1] "2" "3" "4" "5"
```

Cuantiles

Esta medida nos proporciona el valor de la variable tal que la proporción de valores menor o igual que él es α , donde $0 < \alpha < 1$. En R calculamos los cuantiles con la función `quantile`.

Ejemplo

```
# Calculamos los siguientes cuantiles
cuantiles <- quantile(faltas, c(0.1, 0.3, 0.5, 0.7, 0.9))
cuantiles
```

```
## 10% 30% 50% 70% 90%
##   2   3   4   5  22
```

```
# Existen distintos algoritmos para calcular los cuantiles, por defecto se usa el tipo 7.
# El procedimiento de cálculo explicado en clase se corresponde con el tipo 2.
```

```
cuantiles <- quantile(faltas, c(0.1, 0.3, 0.5, 0.7, 0.9), type = 2)
cuantiles
```

```
## 10% 30% 50% 70% 90%
##   2   3   4   5  22
```

Medidas de dispersión

Las medidas de dispersión nos informan de la variabilidad de los datos. En R disponemos de distintas funciones: `var` calcula la cuasivarianza o varianza muestral, `sd` calcula la cuasidesviación típica o desviación típica muestral, `range` calcula el rango o recorrido de los datos e `IQR` el rango intercuartílico. No hay una función para calcular el coeficiente de variación, con lo que tendremos que calcularlo “a mano”.

```
#Cuasivarianza
cuasivar <- var(faltas)
cuasivar
```

```
## [1] 85.29091
```

```
#Varianza
varianza <- (length(faltas) - 1) / length(faltas) * cuasivar
varianza
```

```
## [1] 77.53719
```

```

#o bien

varianza <- sum(faltas ^ 2) / length(faltas) - mean(faltas) ^ 2
varianza

## [1] 77.53719

#Desviación típica muestral

desv <- sd(faltas)
desv

## [1] 9.235308

#Coeficiente de variación muestral
cv = sd(faltas) / mean(faltas)

#Rango
range(faltas)

## [1] 2 30

#Rango intercuartílico (por defecto se utiliza el tipo 7 para el cálculo de los cuantiles)
IQR(faltas, type = 2)

## [1] 4

```

Medidas de forma

Las medidas de forma comparan la estructura de los datos con la que cabría esperar si procediesen de una distribución **Normal** (Campana de Gauss). Estudiaremos la simetría y la curtosis de los datos.

R base no dispone de funciones para el cálculo de estas medidas, por tanto, tenemos dos opciones, o bien usamos funciones de algún paquete que las contenga, o bien las programamos.

Uno de los paquetes que contiene funciones para estos cálculos es **DescTools**. En este paquete encontramos la función **Skew** para el cálculo de la asimetría y la función **Kurt** para la curtosis.

Ejemplo

```

#Para el cálculo del coeficiente de asimetría usando la función Skew cargamos el paquete
#`DescTools`
library("DescTools")
coef.asimetria <- Skew(faltas)
coef.asimetria

## [1] 1.472621

#Existen distintos coeficientes de asimetría. El de Fisher, explicado en clase, se
#corresponde con method = 1

coef.asimetria <- Skew(faltas, method = 1)
coef.asimetria

## [1] 1.698948

#Para el cálculo del coeficiente de curtosis usamos la función Kurt cuyos parámetros son
#similares a la función Skew

```

```
coef.curtosis <- Kurt(faltas)
print(coef.curtosis)
```

```
## [1] 0.5214548
```

```
#Coeficiente de kurtosis de Fisher (explicado en clase)
```

```
coef.curtosis <- Kurt(faltas, method = 1)
print(coef.curtosis)
```

```
## [1] 1.26096
```

Función summary

La función `summary` genera un resumen descriptivo de los datos: - En el caso de datos cuantitativos, muestra las principales medidas de posición (mínimo, máximo, media, mediana, y cuartiles 1 y 3). - En el caso de datos cualitativos, muestra la frecuencia de cada modalidad. Se puede aplicar a un vector o a una hoja de datos.

```
#Aplicado a un vector de datos
```

```
summary(faltas)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      2.000   3.000   4.000   7.909   6.000  30.000
```

```
#Aplicado a un dataframe
```

```
datos <- data.frame(
  Antiguedad = c(15, 19, 14, 3, 10, 18, 11, 5, 20, 14),
  Categoria = factor(c("Mid", "Junior", "Senior", "Senior", "Junior",
    "Senior", "Mid", "Junior", "Senior", "Junior")),
  Errores_Cometidos = c(33,28,4,7,11,12,17,32,26,24),
  Salario_Mensual = c(4794, 4503, 5925, 3182, 2751, 5280, 2373, 3841, 4081, 6611)
)
```

```
summary(datos)
```

```
##      Antiguedad      Categoria Errores_Cometidos Salario_Mensual
##      Min.       : 3.00   Junior:4   Min.       : 4.00   Min.       :2373
##      1st Qu.:10.25   Mid   :2   1st Qu.:11.25   1st Qu.:3347
##      Median :14.00   Senior:4   Median :20.50   Median :4292
##      Mean   :12.90           Mean   :19.40   Mean   :4334
##      3rd Qu.:17.25           3rd Qu.:27.50   3rd Qu.:5158
##      Max.    :20.00           Max.    :33.00   Max.    :6611
```

Detección de valores atípicos


Los datos atípicos o outlier son observaciones “raras”, ya sea porque sus valores son excesivamente grandes o excesivamente pequeños comparados con el resto.

Los datos atípicos no tienen por qué ser valores erróneos, ya que podría tratarse de valores poco probables pero plausibles. La existencia de datos anómalos en un conjunto de datos nos debe poner en guardia e instarnos a investigar si ese dato se debe a un fallo en la recogida o es un dato real poco probable.

En R existen procedimientos avanzados de detección de valores atípicos. Nosotros utilizaremos el **gráfico de caja y bigotes** que nos proporciona la función `boxplot`.

Ejemplo

```
# Generamos el gráfico de caja y bigotes para la variable faltas. Para acceder a los
#valores anómalos, almacenamos la salida en una variable
salida <- boxplot(faltas, main = "Gráfico de caja y bigotes", ylab = "Faltas", col = "blue")
```



```
# Por defecto, se consideran anómalos aquellos valores que caen fuera del intervalo
# (Q1-1.5RIQ,Q3+1.5RIQ).
# Para modificar el valor 1.5, hay que cambiar el argumento `range` de la función.

# Así, los datos atípicos detectados son
salida$out

## [1] 30 22
```

Resumen estadístico por grupos

Dado un conjunto de datos, el estudio estadístico por grupos consiste en realizar un estudio parcial de los individuos o elementos que pertenecen a cada uno de los grupos en los que se dividen los datos, con objeto de hacer comparaciones.

Para ello se utiliza la función `aggregate`.

Ejemplo

```
# A partir de la siguiente hoja de datos calculamos la media, mediana, cuartil 1 y
# cuartil 2, de la variable RAM_GB de los dispositivos para distintas marcas
dispositivos <- data.frame(
  DeviceID = 1:30,
  DeviceType = rep(c("Laptop", "Desktop", "Tablet", "Smartphone", "Server"), each=6),
```



```

Brand = rep(c("Dell", "HP", "Apple", "Samsung", "IBM", "Lenovo"), each=5),
RAM_GB = c(16, 32, 4, 6, 64, 8, 8, 16, 32, 64, 4, 8, 8, 16, 16,
            8, 16, 32, 4, 8, 8, 16, 32, 64, 4, 8, 4, 4, 64, 32),
Storage_GB = c(512, 1024, 64, 128, 2048, 256, 256, 512, 1024, 2048, 64, 128, 256, 512,
                1024, 128, 256, 512, 64, 128, 256, 512, 1024, 2048, 128, 256, 64, 64,
                1024, 2048),
Processor = c("Intel i7", "AMD Ryzen 7", "Apple A14", "Qualcomm Snapdragon 865",
              "Intel Xeon", "Intel i5", "Intel i7", "Intel i5", "AMD Ryzen 5",
              "Intel i9", "Apple M1", "Apple A14", "Exynos 990", "Snapdragon 865",
              "Intel Xeon", "Intel Xeon", "Intel Xeon", "Intel Xeon", "Arm Cortex",
              "Arm Cortex", "Arm Cortex", "Arm Cortex", "Intel Xeon", "Intel Xeon",
              "Intel i5", "Intel i7", "Intel i5", "AMD Ryzen 5", "Intel i9", "Apple M1"),
Price_USD = c(1200, 1500, 800, 999, 5000, 1000, 1100, 1300, 1400, 6000, 800, 900, 1000,
              1100, 1200, 700, 800, 900, 1000, 1100, 4000, 4500, 4800, 5000, 300, 350,
              400, 450, 5000, 6000),
Year = c(2022, 2023, 2021, 2022, 2023, 2020, 2021, 2022, 2023, 2023, 2021, 2020, 2019,
          2021, 2022, 2020, 2021, 2022, 2023, 2023, 2023, 2022, 2021, 2020, 2021, 2022,
          2021, 2020, 2022, 2023)
)

```

Obtenemos la RAM media de cada marca

```
aggregate(RAM_GB ~ Brand, data = dispositivos, FUN = mean)
```

```

##      Brand RAM_GB
## 1   Apple   10.4
## 2    Dell   24.4
## 3     HP    25.6
## 4    IBM    24.8
## 5  Lenovo   22.4
## 6 Samsung   13.6

```

Comparamos la media, mediana, Q1 y Q3 para la variable RAM_GB según la marca

```

aggregate(RAM_GB ~ Brand, data = dispositivos, FUN =
  function(x) c(media = mean(x),
                 mediana = median(x),
                 var = var(x),
                 sd = sd(x),
                 cv = sd(x) / mean(x),
                 Q1 = quantile(x,0.25,type = 2),
                 Q3 = quantile(x,0.75,type = 2)))

```

```

##      Brand RAM_GB.media RAM_GB.mediana RAM_GB.var RAM_GB.sd RAM_GB.cv
## 1   Apple  10.4000000    8.0000000    28.8000000    5.3665631    0.5160157
## 2    Dell  24.4000000   16.0000000   612.8000000   24.7547975    1.0145409
## 3     HP   25.6000000   16.0000000   556.8000000   23.5966099    0.9217426
## 4    IBM   24.8000000   16.0000000   595.2000000   24.3967211    0.9837388
## 5  Lenovo  22.4000000    8.0000000   676.8000000   26.0153801    1.1614009
## 6 Samsung  13.6000000    8.0000000   124.8000000   11.1713920    0.8214259
##      RAM_GB.Q1.25% RAM_GB.Q3.75%
## 1      8.0000000    16.0000000
## 2      6.0000000    32.0000000
## 3      8.0000000    32.0000000

```


```
## 4      8.0000000    32.0000000
## 5      4.0000000    32.0000000
## 6      8.0000000    16.0000000
```

La representación de varios gráficos simultáneos se consigue con el uso de la función `par(mfrow=c(n,m))` que genera una cuadrícula en la que se dibujan los $n \times m$ gráficos.

Ejemplo

#Generamos un gráfico de barras múltiple para comparar los dispositivos de las marcas Dell y HP


```
tablaDell <- table(dispositivos[dispositivos$Brand == "Dell", ]$DeviceType)
tablaHP <- table(dispositivos[dispositivos$Brand == "HP", ]$DeviceType)
par(mfrow = c(1, 2))
barplot(tablaDell, beside = TRUE,
        col = c("lightblue", "mistyrose", "lightcyan",
                "lavender", "cornsilk"),
        ylim = c(0, max(tablaDell)*2))
barplot(tablaHP, beside = TRUE,
        col = c("lightblue", "mistyrose", "lightcyan",
                "lavender", "cornsilk"),
        ylim = c(0, max(tablaHP)*2))
```




También podemos usar bucles para la representación de los gráficos.

Ejemplo

```
tipos <- unique(dispositivos$DeviceType)
par(mfrow = c(2, 2))
for( i in tipos){
  hist(dispositivos[dispositivos$DeviceType == i, ]$RAM_GB, ylab = "Frecuencia",
       xlab = "Ram GB", main = i)
}
```






De igual forma podemos generar varios gráficos de sectores.

Ejemplo


```
par(mfrow = c(1, 2))
pie(tablaDell, main = "Dell")
pie(tablaHP, main = "HP")
```



Para generar varios histogramas actuaremos de la misma forma.

Ejemplo

```
par(mfrow = c(1, 2))
precio <- dispositivos$Price_USD[dispositivos$Brand == "Dell"]
hist(precio, main = "Dell", xlab="Precio dispositivo", ylab = "Número dispositivos")
precio <- dispositivos$Price_USD[dispositivos$Brand == "HP"]
hist(precio, main = "HP", xlab = "Precio dispositivo", ylab = "Número dispositivos")
```




Para representar los gráficos de caja y bigotes conjuntos también se emplea la función `boxplot` a la que le pasaremos como argumentos la variable que pretendemos estudiar y la que utilizaremos para agrupar como una fórmula.

Ejemplo

```
# Gráficos de caja y bigotes por empresas

salida <- boxplot(RAM_GB ~ Brand, data = dispositivos)
```



```
# Consultamos los valores anómalos
salida$out
```

```
## [1] 32
```

```
# Para saber a qué elemento corresponde hacemos un filtro con RAM_GB == 32 & Brand == 'Samsung'
dispositivos[dispositivos$RAM_GB == salida$out & dispositivos$Brand == 'Samsung', ]
```

```
##      DeviceID DeviceType  Brand RAM_GB Storage_GB Processor Price_USD Year
## 18          18    Tablet Samsung    32         512 Intel Xeon      900 2022
```

EJERCICIOS

Para la resolución de los ejercicios cargue los datos del fichero practica3.Rdata, disponible en la plataforma de docencia virtual.

Ejercicio 1: Descripción de variables cualitativas

Contruya la tabla de frecuencias y represente los gráficos apropiados para los datos de las variables **Provincia** y **PrincipalProcedenciaExtran**. A partir de los resultados, responda a las siguientes preguntas:

- ¿Cuál es la provincia con más municipios? ¿Y con menos?
- ¿Qué provincias tienen más de 100 municipios?
- ¿Qué nacionalidad extranjera es la principal en los municipios de Andalucía? ¿De qué medida se trata? ¿Cuál es su proporción sobre el total?
- Genere los gráficos y tablas adecuados para contestar a la siguiente pregunta. ¿Cuál es la nacionalidad predominante en los municipios de cada provincia?

Ejercicio 2: Descripción de variables cuantitativas

1. Realice un estudio descriptivo de la variable **Altitud19** para el conjunto de los municipios de Andalucía y para los municipios de cada provincia. A continuación conteste a las siguientes cuestiones:
 - a) ¿Cuál es la altitud media de los municipios de Andalucía? ¿Cuál es la altitud media de los municipios de cada provincia? ¿Qué provincias tienen una altitud media superior a la media de los municipios de Andalucía?
 - b) ¿En qué provincia los datos sobre la altitud media de los municipios son más homogéneos?
 - c) Calcule los coeficientes de asimetría y curtosis para la variable altitud en cada provincia y compárelos.
 - d) ¿Qué municipios andaluces destacan como atípicos sobre el resto, en cada provincia, por su alta o baja altitud?
2. Construya una tabla de frecuencias para la variable **RentaBruta** en la provincia de Málaga, con 9 intervalos de amplitud 3000, comenzando en 13000. A partir de la tabla anterior, responda a las siguientes cuestiones:
 - a) ¿Cuántos municipios tienen una renta bruta superior a 28000€? ¿Y mayor que 19000€ y menor o igual a 31000?
 - b) ¿Cuál es el intervalo de renta bruta más usual en los municipios de Málaga?
3. Represente el histograma para la variable **RentaBruta** en los municipios de la provincia de Málaga, utilizando los mismos intervalos del ejercicio anterior. A partir de él, ¿qué opina sobre la simetría de los datos?