

Tema 5.
Introducción a la
Inferencia
Estadística.

Índice.

1. Introducción.
2. Muestra aleatoria simple.
3. Función de distribución muestral.
4. Estadísticos muestrales.
5. Distribuciones asociadas al muestreo (poblaciones normales).
 - 5.1. Media muestral.
 - 5.2. Varianza muestral.
 - 5.3. Proporción muestral.
 - 5.4. Diferencia de medias muestrales.
 - 5.5. Cociente de varianzas muestrales.
 - 5.6. Diferencia de proporciones muestrales.
6. Propiedades de los estimadores.
 - 6.1. Insesgadez.
 - 6.2. Eficiencia.
 - 6.3. Consistencia.
 - 6.4. Suficiencia.
7. Métodos de estimación puntual.
8. Construcción de un intervalo de confianza.
9. Intervalos de confianza para medias, varianzas y proporciones.

1. Introducción.

El principal **objetivo** de la Estadística, en particular de la Inferencia Estadística, es inferir o estimar características de una población que no es completamente observable a través del análisis de una muestra.

La **selección de la muestra** es de suma importancia y existen diversos métodos.

Cuando se intuye que la característica en estudio puede presentar valores homogéneos en la población, una forma de obtener una muestra representativa es seleccionada al **azar**.
(muestreo aleatorio simple)

Otros métodos de muestreo son:

- **Muestreo sistemático:** Alternativa al muestreo aleatorio simple.
- **Muestreo por cuotas:** Es una alternativa al muestreo estratificado, la selección debe de hacerse respetando unos porcentajes (*cuotas*)
- **Muestreo estratificado:** Se utiliza cuando la muestra no es homogénea, es decir, presenta alta variabilidad.
- **Muestreo por conglomerados:** Consiste en dividir la población en subpoblaciones parecidas entre sí y heterogéneas internamente.
- **Muchos más.**

A la proporción de individuos en la población seleccionados en la muestra se le llama **fracción de muestreo** (cociente entre el tamaño muestral y el tamaño de la población)

La **Inferencia Estadística** se puede clasificar en dos tipos:

- **Inferencia paramétrica:** Ocurre cuando la distribución de la *variable de estudio* en la población es *conocida* y el *interés de estudio* recae sobre los *parámetros desconocidos* de esta. Los problemas que veremos son:
 - Estimación de parámetros: Se busca un valor (**estimación puntual**) o un conjunto de valores posibles para el mismo (**estimación por intervalos de confianza**)
 - Contrastes de hipótesis: Su objetivo es comprobar si es cierta o falsa cierta hipótesis formulada sobre el parámetro.
- **Inferencia no paramétrica:** Ocurre cuando se *desconoce la distribución de la variable* de estudio y sólo suponemos propiedades generales de esta.

2. Muestra aleatoria simple.

En la práctica difícilmente se obtienen las observaciones de una población completa, esta es una de las **principales razones** de las que por qué se trabaja con una muestra. Otras razones también pueden ser las siguientes:

- **Economía.**
- **Tiempo:** Si se obtiene una población muy grande llevaría mucho tiempo poder analizarla, incluso pudiendo cambiar esta población durante el análisis de la misma.
- **Destrucción:** La medición de cierta característica podría llevar a la destrucción del individuo.

Para poder realizar una inferencia correctamente sobre una población, debes de asegurarte que se verifica la **representatividad y aleatoriedad** de la muestra.

Una de las formas de verificar la *representatividad* es cuando el proceso de muestreo proporciona a cada elemento la oportunidad **igual e independiente** de ser incluido en la muestra.

A esto es a lo que llamamos **muestra aleatoria simple**, que consiste en seleccionar una muestra, **n**, de una población, **N**, en donde cada elemento tiene la misma probabilidad de ser elegido.

Se exige que sea una muestra elegida **aleatoriamente** porque así se puede conocer el error que se comete al utilizar la muestra como reflejo de la población.

Puedes encontrarte con dos tipos de **procedimientos** para extraer la muestra, que son los siguientes:

- **Muestreo aleatorio simple con reemplazamiento:** En este procedimiento se va extrayendo una muestra de la población, se analiza y antes de volver a extraer otra muestra, la anterior vuelve a incluirse en la población. Los ensayos que se realizan son independientes y se realizan tantos como tamaño de **n** se quiere tener en la muestra.
- **Muestreo aleatorio simple sin reemplazamiento:** En este caso, al contrario que en el anterior, la muestra que se extrae de la población no se vuelve a incluir.

La diferencia entre ambos procedimientos es que en el *muestreo aleatorio simple con reemplazamiento* las observaciones son variables **independientes e idénticamente distribuidas**, mientras que en el *muestreo aleatorio simple sin reemplazamiento*, las observaciones **no son independientes**.

2. Muestra aleatoria simple.

DEFINICIÓN 1:

Sea X una variable aleatoria con función de distribución F , y sean $X_1, X_2, \dots, X_n$ variables aleatorias independientes e idénticamente distribuidas según la función de distribución F . Decimos entonces que $X_1, X_2, \dots, X_n$ es una **muestra aleatoria simple de X** .

DEFINICIÓN 2:

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria simple de una variable aleatoria X con función de distribución F . Llamamos **realización muestral o realización de la muestra** al conjunto de valores $x_1, x_2, \dots, x_n$ que se han observado en las variables de la muestra.

$$X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$$

DEFINICIÓN 3:

Un **parámetro** es un valor numérico fijo, normalmente desconocido, de la distribución de probabilidad de la población, de manera que describe parcial o totalmente la distribución de la variable aleatoria X . Cuando aparece más de un parámetro lo llamaremos **vector paramétrico**, lo notaremos por:

$$\theta = (\theta_1, \dots, \theta_n) \in \mathbb{R}$$

2. Muestra aleatoria simple.

EJEMPLO 1:

Consideremos en una población una variable X de interés cuya función de distribución es $F(x)$, como podría ser el tiempo de espera para recibir un servicio, o el valor de las ventas de un determinado producto. Entonces, para seleccionar una muestra aleatoria de tamaño n de esta población, podríamos diseñar un experimento de tal manera que la primera realización de este experimento nos proporciona la primera observación de la característica, $X_1 = x_1$, y repitiendo sucesivamente el experimento bajo las mismas condiciones obtendríamos las n observaciones de la muestra aleatoria simple.

EJEMPLO 2:

Se lanza una moneda y asociamos al experimento una variable aleatoria X que toma los siguientes valores:

$$X = \begin{cases} 1 & \text{si sale cara} \\ 0 & \text{si sale cruz} \end{cases}$$

y que se distribuye según una Bernoulli de parámetro p .

Supongamos que se lanza 20 veces la moneda y denotamos por X_i el resultado obtenido en el lanzamiento i , $i=1, 2, 3, \dots, 20$. Entonces $X_1, \dots, X_n$ es una muestra aleatoria simple, es decir, dichas variables son independientes y con distribución Bernoulli p . Si las observaciones obtenidas son $(1, 1, 0, 1, 0, \dots, 1)$, tenemos una realización de muestra. Si lanzamos otras 20 veces la moneda obtendríamos otra realización muestral.

2. Muestra aleatoria simple.

EJEMPLO 3:

Supongamos que se estudia la vida media de una población de bombillas. Para ello definimos una variable aleatoria X que mide el tiempo de vida de una bombilla. Se sabe que X sigue una distribución Exponencial con parámetro λ , siendo λ el tiempo medio de vida, y es el valor que queremos estimar. Para ello seleccionamos una muestra aleatoria simple de la población de bombillas, $X_1, X_2, \dots, X_n$.

Nos interesa conocer la función de probabilidad conjunta de esas n variables aleatorias independientes de la muestra. Dado que la función de densidad de la Exponencial de parámetro λ es:

$$f(x) = \lambda e^{-\lambda x}, \quad x > 0$$

se tiene que para una realización muestral $x_1, x_2, \dots, x_n$.

$$f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i) = \frac{1}{\lambda^n} e^{-\lambda \sum x_i}, \quad \text{con } x_1, x_2, \dots, x_n > 0$$

ya que son independientes.

Esta es la distribución conjunta de la muestra y representa la información conjunta que proporciona la muestra obtenida. Veremos más adelante que recibe el nombre de **función de verosimilitud**.

3. Función de distribución muestral.

Como señalan **Ruiz-Maya y Martín-Priego**, 'en general, en una muestra concreta, sus características no tienen por qué coincidir exactamente con las correspondientes de la población a causa de la aleatoriedad del procedimiento de extracción de los elementos, [...] pero es de esperar que los valores de las características muestrales no se alejen demasiado de los poblacionales.'

DEFINICIÓN 4:

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria simple de una variable aleatoria X con una distribución $F(x)$. Denotamos por $x_{(1)}, x_{(2)}, \dots, x_{(n)}$ a una realización muestral ordenada. Definimos entonces la función de distribución muestral de la forma siguiente:

$$F_n(x) = \begin{cases} 0 & \text{si } x < x_{(1)} \\ \frac{k}{n} & \text{si } x_{(k)} \leq x < x_{(k+1)} \quad k = 1, \dots, n-1 \\ 1 & \text{si } x \geq x_{(n)} \end{cases}$$

En otras palabras, para cualquier valor de $x \in \mathbb{R}$, $F_n(x)$ representa la proporción de valores en la muestra ordenada inferiores o iguales a x .

TEOREMA 1: (TEOREMA DE GLIVENKO-CANTELLI)

$F_n(x)$ converge uniformemente a $F(x)$, es decir, para todo $\varepsilon > 0$, se verifica que:

$$\lim_{n \rightarrow \infty} P\left[\sup_x |F_n(x) - F(x)| < \varepsilon\right] = 1$$

Este resultado **garantiza** que la distribución de la muestra está tan próxima a la distribución poblacional como se quiera, siempre y cuando n sea suficientemente grande y con una confianza determinada. Además, esto implica que las **características muestrales**, bajo condiciones generales, convergen en probabilidad a las correspondientes poblacionales.

Por lo tanto, a través de la muestra podemos conocer la distribución de la característica en estudio. Y es por esto por lo que el proceso de muestreo resulta ser una herramienta válida para realizar inferencias sobre la característica poblacional en estudio, y refleja la importancia de este resultado.

3. Función de distribución muestral.

EJEMPLO 4:

Se está realizando un estudio sobre el consumo medio semanal de un determinado producto. Una muestra de 10 semanas proporciona los siguientes resultados:

2, 1, 2, 0, 3, 1, 1, 2, 0, 4

Vamos a calcular la función de distribución muestral. En primer lugar ordenamos los datos de la muestra:

0, 0, 1, 1, 1, 2, 2, 2, 3, 4

Entonces:

$$F_n(x) = \begin{cases} 0 & x < 0 \\ 0.2 & 0 \leq x < 1 \\ 0.5 & 1 \leq x < 2 \\ 0.8 & 2 \leq x < 3 \\ 0.9 & 3 \leq x < 4 \\ 1 & x \leq 4 \end{cases}$$

4. Estadísticos muestrales.

Obtenida una **muestra de la población**, veremos cómo proceder hasta llegar a dichas estimaciones.

DEFINICIÓN 5:

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria simple de una variable aleatoria X de una población, y sea una función

Si T es medible y no depende de ningún vector paramétrico, se dice que T es un **estadístico**. Es decir, un estadístico es una función de la muestra que no depende de ningún parámetro desconocido. Lo notaremos por tanto $T(X_1, \dots, X_n)$

4. Estadísticos muestrales.

EJEMPLO 5:

Consideremos una muestra de las siguientes distribuciones.

- a) Sea $X \rightarrow B(1,p)$, con p desconocido. Entonces, $T(X_1, \dots, X_n) = \sum_{i=1}^n x_i$ es un estadístico muestral.
- b) Sea $X \rightarrow N(\mu, \sigma)$ con μ conocido y σ desconocido.

Entonces:

$$T(X_1, \dots, X_n) = \sum_{i=1}^n (X_i - \mu) \text{ es un estadístico muestral}$$

$$T(X_1, \dots, X_n) = \frac{1}{\sigma} \prod_{i=1}^n X_i \text{ no es un estadístico muestral}$$

Veamos algunos estadísticos muy utilizados:

- **Media muestral**

$$\bar{X} = \frac{X_1 + \dots + X_n}{n}$$

- **Varianza muestral**

$$S^2 = \frac{\sum_{i=1}^n (x_i - \bar{X})^2}{n-1}$$

Si un estadístico lo usamos para estimar un parámetro desconocido de la población lo llamaremos **estimador** de ese parámetro. Al valor que toma una vez observada la muestra se le llama **estimación puntual** del parámetro. El error de estimación depende fundamentalmente de la variabilidad poblacional y del tamaño de la muestra.

5. Distribuciones asociadas al muestreo (poblaciones normales)

Dado que las muestras que se pueden tomar de una característica X no son únicas, el estadístico formado a partir de ellas posee una variabilidad, un estadístico es una variable aleatoria.

DEFINICIÓN 6:

La **distribución en el muestreo de un estimador T** es la distribución de probabilidad de T que puede obtenerse como resultado de un número infinito de muestras aleatorias independientes, cada una de tamaño n , procedentes de la población de interés.

El propósito que vais a seguir ahora es obtener las distribuciones en el muestreo de algunos estadísticos importantes como son:

- Media muestral.
- Varianza muestral.
- Proporción muestral.

Estas siguen una población normal.

En el caso de tener dos poblaciones normales, los estadísticos importantes que veréis son:

- Diferencia de medias muestrales.
- Cociente de varianzas muestrales.
- diferencias de proporciones muestrales.

5. Distribuciones asociadas al muestreo (poblaciones normales)

5.1. Media muestral.

Sea $X_1, \dots, X_n$ una muestra aleatoria simple de una población X con distribución $N(\mu, \sigma)$. Entonces,

$$\bar{X} = \frac{X_1 + \dots + X_n}{n} \rightarrow N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

al ser una combinación lineal de variables normales e independientes.

5.2. Varianza muestral.

Sea $X_1, \dots, X_n$ una muestra aleatoria simple de una población X con distribución $N(\mu, \sigma)$. Entonces,

$$\frac{(n-1)S^2}{\sigma^2} \rightarrow \chi^2_{n-1}$$

siendo

$$S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$$

la varianza muestral, y $\bar{X}$ y S^2 son independientes.

5. Distribuciones asociadas al muestreo (poblaciones normales)

5.1. Media muestral.

5.2. Varianza muestral.

EJEMPLO:

Una multinacional desea comprar una cadena de supermercados. Antes de finiquitar el trato, decide echar un vistazo a los registros financieros de 50 de los supermercados de la cadena. La directiva de ésta afirma que las ganancias semanales de cada tienda tienen una distribución normal con la misma media de **400€** y una desviación estándar de **80€**.

a) ¿Cuál es la probabilidad de que la media de la muestra de los 50 supermercados supere los 500€?

Llamamos X_i a las ganancias semanales del supermercado i , $i=1, 2, \dots, 50$. Las variables $X_1, \dots, X_{50}$ son independientes y con idéntica distribución, $N(400, 80)$

Entonces sabemos que

$$\bar{X} = \frac{X_1 + \dots + X_{50}}{50} \rightarrow N\left(400, \frac{80}{\sqrt{50}}\right)$$

La probabilidad que buscamos es

$$P(\bar{X} > 500) = P\left(Z > \frac{500 - 400}{\frac{80}{\sqrt{50}}}\right)$$

5. Distribuciones asociadas al muestreo (poblaciones normales)

5.1. Media muestral.

5.2. Varianza muestral.

EJEMPLO:

b) Calcular la probabilidad de que la varianza muestral sea inferior a 50€

En este caso consideramos la distribución

$$\frac{(n-1) S^2}{\sigma^2} \rightarrow \chi^2_{n-1}$$

que sustituyendo resulta:

$$Y = \frac{49S^2}{80} \rightarrow \chi^2_{49}$$

Con lo que

$$P(S^2 < 50) = P\left(\frac{49S^2}{80^2} < 50 \cdot \frac{49}{80^2}\right) = P\left(Y < 50 \cdot \frac{49}{80^2}\right)$$

c) Supongamos que se obtiene en la muestra una varianza igual a 76,2, ¿cuál sería entonces la probabilidad de que la media muestral de los 50 supermercados superará los 500€?

Sabemos que la media muestral y la varianza muestras son independientes, con lo cual, el conocer el valor de la varianza muestral no afecta a la probabilidad buscada para la media. El resultado sería, por tanto, el obtenido en el apartado a

5. Distribuciones asociadas al muestreo (poblaciones normales)

5.3. Proporción muestral.

Sea $X_1, \dots, X_n$ una muestra aleatoria simple de una población X . Sea p la proporción de individuos en la población que presentan una determinada característica, y $\hat{p}$ la proporción muestral. Entonces,

$$\hat{p} \rightarrow N\left(\hat{p}, \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}\right)$$

Nota: El número de individuos que presentan la característica en la muestra sigue una distribución $B(n, p)$, que con n suficientemente grande se puede aproximar a una

Por lo tanto, la proporción muestral sigue también una distribución Normal con los parámetros anteriormente indicados.

5.4. Diferencia de medias muestrales.

Sea $X_1, \dots, X_{n1}$ una muestra aleatoria simple de una población X e $Y_1, \dots, Y_{n2}$ una muestra aleatoria simple de una población Y .

Suponemos que las poblaciones X e Y son independientes y con distribuciones normales $N(\mu_1, \sigma_1^2)$ y $N(\mu_2, \sigma_2^2)$ respectivamente.

a) σ_1^2, σ_2^2 conocidas:

$$\bar{X} - \bar{Y} \rightarrow N\left(\mu_1 - \mu_2, \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}\right)$$

o equivalentemente

$$Z = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \rightarrow N(0, 1)$$

b) $\sigma_1^2 = \sigma_2^2 = \sigma^2$ desconocidas

$$T = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \rightarrow t_{n_1 + n_2 - 2}$$

siendo

$$S_p = \sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}}$$

y si S_1^2 y S_2^2 las varianzas muestrales de X e Y respectivamente.

5. Distribuciones asociadas al muestreo (poblaciones normales)

5.5. Cociente de varianzas muestrales.

Sea $X_1, \dots, X_{n1}$ una muestra aleatoria simple de una población X e $Y_1, \dots, Y_{n2}$ una muestra aleatoria simple de una población Y . Suponemos que las poblaciones X e Y son independientes y con distribuciones normales $N(\mu_1, \sigma_1^2)$ y $N(\mu_2, \sigma_2^2)$ respectivamente. Entonces,

$$F = \frac{\frac{S_1^2}{\sigma_1^2}}{\frac{S_2^2}{\sigma_2^2}} \rightarrow F_{n_1-1, n_2-1}$$

Estudiamos además la distribución de una proporción muestral y de la diferencia de dos proporciones muestrales, con muestras procedentes de poblaciones independientes.

5.6. Diferencia de proporciones muestrales

Sea $X_1, \dots, X_{n1}$ una muestra aleatoria simple de una población X e $Y_1, \dots, Y_{n2}$ una muestra aleatoria simple de una población Y . Denotamos por p_1 y p_2 las proporciones poblacionales y por p_1 y p_2 las correspondientes proporciones muestrales. Entonces:

$$p_1 - p_2 \rightarrow N\left(p_1 - p_2, \sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_1}}\right).$$

Por lo tanto:

$$Z = \frac{p_1 - p_2 - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_1}}} \rightarrow N(0, 1)$$

6. Propiedades de los estimadores.

En este apartado se van a analizar algunas de las propiedades estadísticas que deben de cumplir un estadístico para que sea el mejor estimador de un parámetro θ .

- **Propiedad de insesgadez.** El valor esperado de θ . debe de coincidir con el valor del parámetro a estimar.
- **Propiedad de eficiencia.** El valor de θ debe de aproximarse al verdadero valor del parámetro a estimar, es decir, minimizar el Error Cuadrático Medio (ECM).
- **Propiedad de consistencia.** Para un tamaño n suficientemente grande, θ toma un valor tan próximo como se quiera al verdadero valor del parámetro.
- **Propiedad de suficiencia.** θ utiliza toda la información de la muestra respecto al parámetro a estimar.

6. Propiedades de los estimadores.

2.1. Inssegadez.

DEFINICIÓN:

Se dice que un estimador $\hat{\theta} = T(X_1, X_2, \dots, X_n)$ de un parámetro θ es inssegado si

$$E(\hat{\theta}) = \theta$$

Si el estimador no es inssegado se dice sesgado, y la diferencia entre su valor esperado y el verdadero valor del parámetro se llama sesgo.

$$b(\hat{\theta}) = E(\hat{\theta}) - \theta$$

Esta propiedad es de una variable aleatoria y no de un valor concreto del estimador, por lo que debemos de entender que la esperanza a la que nos referimos es a la del conjunto de todos los valores que puede presentar el estimador.

Un estimador inssegado de un parámetro no tiene por qué ser el único, sino que pueden existir infinitos estimadores inssegados de un mismo parámetro, por lo que se busca el que se más óptimo.

2.2. Eficiencia.

Esta propiedad permite que seleccionemos el estimador más óptimo entre varios que son inssegados.

DEFINICIÓN 1:

Sea $\hat{\theta} = T(X_1, \dots, X_n)$ cualquier estimador de un parámetro θ . Se define el error cuadrático medio de θ como:

$$ECM(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$

En este sentido, un estimador será más fiable cuanto menor error cuadrático medio presente, y se dirá óptimo si hace mínimo dicho error. Se puede comprobar que:

$$ECM(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + (E[\hat{\theta}] - \theta)^2$$

Si un estimador $\hat{\theta}$ es inssegado, entonces $ECM(\hat{\theta}) = \text{Var}(\hat{\theta})$, por lo que se concluye que el mejor estimador inssegado será aquel que tenga varianza mínima.

6. Propiedades de los estimadores.

2.2. Eficiencia.

DEFINICIÓN 2:

Sean θ_1 y θ_2 dos estimadores insesgados de θ , obtenidos en muestras del mismo tamaño. Entonces, se dice que θ_1 es más eficiente que θ_2 para θ si:

$$Var(\widehat{\theta}_1) < Var(\widehat{\theta}_2)$$

El UMVUE es el estimador más eficiente de entre todos los estimadores insesgados para θ .

Si realmente lo que quieres es comparar cuál es el estimador más eficiente entre todos lo que se hace es comparar la varianza de estos con la **cota de Cramér-Rao**.

DEFINICIÓN 3:

Sea $X_1, \dots, X_n$ una muestra aleatoria simple de una población X definida por la función de probabilidad $f_\theta(x)$ con θ desconocido. Un estimador insesgado $\theta = T(X_1, \dots, X_n)$ del parámetro θ , con varianza finita, se dice que es eficiente para el θ si alcanza la **cota de Cramér-Rao**.

$$Var(\theta) = \frac{1}{nE\left[\left(\frac{\partial \ln f_\theta(x)}{\partial \theta}\right)^2\right]}$$

La cota de Cramér-Rao permite determinar si un estimador insesgado es eficiente. Sin embargo, este resultado no implica necesariamente que siempre existe un estimador insesgado cuya varianza alcance la cota.

6. Propiedades de los estimadores.

2.3. Consistencia.

Si el tamaño muestral aumenta, la información proporcionada sobre la población es cada vez mayor, llegando así a coincidir la muestra con la población y la estimación puntual con el parámetro a estimar (**Teorema de Glivenko-Cantelli**).

DEFINICIÓN:

Sea un estimador del parámetro θ de una población X definida por la función de probabilidad $f_{\theta}(x)$. Sea $\theta_1, \theta_2, \dots, \theta_n$ una secuencia de estimadores que representan a θ con base a muestras de tamaño $1, 2, \dots, n$ respectivamente. Se dice que θ estimado es un **estimador consistente** para θ si y sólo si para todo $\varepsilon > 0$.

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \varepsilon) = 1$$

Desigualdad de Chebyshev: Sea X una variable aleatoria con esperanza μ y varianza σ^2 . Entonces para cualquier constante $k > 0$.

$$P(|X - \mu| < k\sigma) \geq 1 - \frac{1}{k^2} \text{ o lo que es igual } P(|X - \mu| < k) \geq 1 - \frac{\sigma^2}{k^2}$$

TEOREMA:

Sea $\{\theta_n\}$ una sucesión de estimadores de θ verificando las siguientes condiciones:

1. $\lim_{n \rightarrow \infty} E[\hat{\theta}_n] = \theta$
2. $\lim_{n \rightarrow \infty} Var[\hat{\theta}_n] = 0$

Entonces, el estimador $\hat{\theta}$ es consistente para θ .

6. Propiedades de los estimadores.

2.4. Suficiencia.

Para saber si un parámetro es suficiente, utilizamos toda la información relevante en una muestra para la estimación de θ .

Se puede describir esta propiedad de un estimador al referirnos a la distribución o densidad de probabilidad condicional de los valores muestrales.

DEFINICIÓN:

Un estimador $\hat{\theta} = T(X_1, \dots, X_n)$ del parámetro θ es suficiente si y sólo si para cada valor del estimador la distribución o densidad de probabilidad condicional de la muestra $X_1, \dots, X_n$, dado un valor del estimador, es independiente de θ .

Esta definición para saber si el estadístico es suficiente es por operativa, por lo que en la práctica se utiliza el procedimiento denominado **Teorema de factorización de Fisher-Neyman**.

TEOREMA (Fisher-Neyman):

Sea $X_1, \dots, X_n$ una muestra aleatoria simple de una población X definida por la función de probabilidad $f_{\theta}(x)$. Entonces, $\theta = T(X_1, \dots, X_n)$ es un estimador suficiente del parámetro θ si y sólo si la distribución de probabilidad conjunta de las variables de la muestra se puede factorizar de manera que:

$$f_{\theta}(x_1, \dots, x_n) = h(x_1, \dots, x_n) g(\theta, \hat{\theta})$$

donde $h(x_1, \dots, x_n)$ es una función no negativa que sólo depende de la muestra, y $g(\theta, \hat{\theta})$ es una función no negativa que depende de θ y $\hat{\theta}$.

6. Propiedades de los estimadores.

EJEMPLO:

En un proceso de control de la calidad se realizaron 5 mediciones de una característica de calidad de un producto, obteniéndose los siguientes resultados: **3, 1, 6, 2, 5**. Suponiendo que la distribución de la característica de calidad de dicho producto viene dada por:

$$f(x) = 0.5\alpha^{-3}x^2 \exp\left\{-\frac{x}{\alpha}\right\}, x > 0$$

$$\text{con } E[X] = 3\alpha \text{ y } \text{Var}[X] = 3\alpha$$

$$\text{Considerando como estimador de } \alpha \text{ el siguiente } \hat{\alpha} = \frac{\bar{X}}{3}$$

- a) ¿Cuál es el valor estimado para la realización muestral dada?
- b) Comprobar si el estimador de α es insesgado.
- c) Calcular la cota de Cramér-Rao ¿Podemos decir que tal estimador es eficiente?
- d) Comprobar la consistencia del estimador.

6. Propiedades de los estimadores.

$$a. \hat{\alpha} = \frac{\bar{X}}{3} = \frac{17}{15} = 1.13$$

b. Dado que $X_1, \dots, X_5$ constituyen una muestra aleatoria simple de X , dichas variables son independientes y presentan la densidad dada por $f(x)$

$$E[\hat{\alpha}] = E\left[\frac{\bar{X}}{3}\right] = E\left[\frac{\sum E[X_i]}{15}\right] = \frac{1}{15} \sum E[X_i] = \frac{15\alpha}{15} = \alpha$$

Por lo que concluimos que el estimador es insesgado.

$$c. \frac{1}{nE\left[\left(\frac{\partial}{\partial \alpha} \ln f(x, \alpha)\right)^2\right]} = \frac{\alpha^2}{3n} = \text{Var}[\hat{\alpha}]$$

por lo que podemos decir que α es un estimador consistente para α

$$d. E[\hat{\alpha}] = \alpha \xrightarrow{n \rightarrow \infty} \alpha$$

$$\text{Var}[\hat{\alpha}] = \alpha \xrightarrow{n \rightarrow \infty} 0$$

por lo que podemos afirmar que el estimador es consistente

7. Métodos de estimación puntual.

Para poder realizar la estimación del mejor parámetro, usamos dos métodos que se explican a continuación.

Método de los máxima verosimilitud:

Consiste en tomar como valor del parámetro aquel que maximice la probabilidad de que ocurra la muestra observada.

Si $X_1, \dots, X_n$ es una muestra de una población con distribución F_θ o densidad $f_\theta(x)$, la probabilidad de que ocurra una realización $x_1, \dots, x_n$.

$$L_\theta(x_1, \dots, x_n) = \prod_{i=1}^n f_\theta(x_i)$$

A $L_\theta(x_1, \dots, x_n)$ se le llama **función de verosimilitud**.

Buscamos entonces el valor de θ que maximice la función de verosimilitud, y al valor obtenido se le llama estimación por máxima verosimilitud de θ .

El estimador máximo verosímil (EMV) de un parámetro no tiene por qué existir y no tiene por qué ser único.

Las **propiedades** que tiene este estimador son:

- No siempre son insesgados.
- Bajo condiciones generales, son consistentes.
- Si existe un estimador eficiente para un parámetro, éste es el obtenido por máxima verosimilitud.
- Si $T=T(X_1, \dots, X_n)$ es un estimador suficiente para el parámetro θ , entonces el estimador máximo verosímil de θ es función de $T=T(X_1, \dots, X_n)$
- Propiedad de invarianza: si $\theta = T(X_1, \dots, X_n)$ es el EMV de θ , cualquier función continua del estimador, $g(\theta)$, es el EMV de $g(\theta)$

7. Métodos de estimación puntual.

Para poder realizar la estimación del mejor parámetro, usamos dos métodos que se explican a continuación.

Método de los momentos:

Consiste en igualar momentos poblacionales a momentos muestrales. Deberemos tener tantas igualdades como parámetros a estimar.

Momento poblacional de orden r

$$\alpha_r = E(X^r)$$

Momento muestral de orden r

$$\alpha_r = \frac{\sum_{i=1}^n X_i^r}{n}$$

EJEMPLO:

Sea $X \rightarrow N(\mu, \sigma)$ con μ desconocido. Seleccionada una muestra aleatoria simple $X_1, \dots, X_n$ con realización $x_1, \dots, x_n$ estimamos el parámetro μ por ambos métodos.

Por el método de máxima verosimilitud.

$$L_{\mu}(x_1, \dots, x_n) = \prod_{i=1}^n f_{\mu}(x_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

si maximizamos μ en tal función, lo realizamos a través del logaritmo

$$\ln L_{\mu}(x_1, \dots, x_n) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 - n \ln(\sqrt{2\pi\sigma})$$

derivamos el logaritmo

$$\frac{\partial}{\partial \mu} \ln L_{\mu}(x_1, \dots, x_n) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = \frac{n\bar{x} - n\mu}{\sigma^2} = 0 \Leftrightarrow \hat{\mu} = \bar{x}$$

Según el método de los momentos:

$$E(X) = \frac{\sum_{i=1}^n x_i}{n} = \bar{X} \text{ de esto tenemos que } \mu = E(X), \text{ entonces } \hat{\mu} = \bar{x}$$

8. Construcción de un Intervalo de Confianza.

Hay que seguir los siguientes pasos para poder construir un **Intervalo de Confianza**.

- Seleccionamos una muestra aleatoria simple.
- Buscamos un estadístico que incluya el parámetro a estimar y que tenga distribución conocida.
- Fijamos el nivel de confianza $1-\alpha$
- Encontramos $T_1(X_1, \dots, X_n)$ y $T_2(X_1, \dots, X_n)$ tales que:
$$P[T_1(X_1, \dots, X_n) \leq \theta \leq T_2(X_1, \dots, X_n)] = 1 - \alpha$$

Una vez observada la muestra, diremos entonces que

$$[T_1(X_1, \dots, X_n), T_2(X_1, \dots, X_n)]$$

es un **Intervalo de confianza**.

Observaciones:

- El intervalo depende de la muestra seleccionada.
- La amplitud del intervalo mide la precisión de la estimación.
- A mayor tamaño muestral n , menos amplitud, y por lo tanto mayor precisión en la estimación. Por otro lado, cuanto mayor es el nivel de confianza, mayor es la amplitud del intervalo.

EJEMPLO 1:

Queremos construir un Intervalo de Confianza para la media μ de una normal con varianza conocida σ^2 .

En este caso el estadístico es:

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma_\theta}{\sqrt{n}}} \rightarrow N(0, 1)$$

Por lo entonces;

$$P\left(-z_{1-\frac{\alpha}{2}} \leq \frac{\bar{X} - \mu}{\frac{\sigma_\theta}{\sqrt{n}}} \leq z_{1-\frac{\alpha}{2}}\right) = 1 - \alpha$$

y despejando se obtiene que

$$P\left(\bar{x} - \frac{\sigma_\theta}{\sqrt{n}} \cdot z_{1-\frac{\alpha}{2}} \leq \mu \leq \bar{x} + \frac{\sigma_\theta}{\sqrt{n}} \cdot z_{1-\frac{\alpha}{2}}\right) = 1 - \alpha$$

El intervalo para μ a $(1-\alpha) \%$ de confianza es entonces $\left[\bar{x} \pm \frac{\sigma_\theta}{\sqrt{n}} z_{1-\frac{\alpha}{2}}\right]$

8. Construcción de un Intervalo de Confianza.

EJEMPLO 2:

El precio de un determinado artículo perecedero en los comercios de alimentación de una ciudad sigue una distribución normal. Se toma una muestra aleatoria de 10 comercios y se observa el precio de ese artículo, obteniéndose una media de 2,35€/Kg. La desviación típica poblacional es conocida e igual a 1.

Obtener un IC al 95% de confianza para el precio promedio de este artículo.

$$\left[\bar{x} \pm \frac{\sigma_0}{\sqrt{n}} z_{1-\frac{\alpha}{2}} \right] = \left[2.35 \pm \frac{1}{\sqrt{10}} 1.96 \right] = [1.7302, 2.9698]$$

A continuación observaremos cómo se calculan los intervalos de confianza para la media, varianza y proporción de una población. Para dos poblaciones aprenderemos a estimar con intervalos de confianza para la diferencia de medias, cociente de varianzas y diferencia de proporciones de dos poblaciones.

9. Intervalos de Confianza para medias, varianzas y proporciones

Intervalo de confianza para media de una normal.

$$\text{Varianza conocida } (\sigma_0^2) \rightarrow \mu \in \left[\bar{x} \pm \frac{\sigma_0}{\sqrt{n}} z_{1-\frac{\alpha}{2}} \right]$$

$$\text{Varianza desconocida} \rightarrow \mu \in \left[\bar{x} \pm \frac{S}{\sqrt{n}} t_{1-\frac{\alpha}{2}, n-1} \right]$$

Intervalo de confianza para la diferencia de medias de dos poblaciones normales e independientes.

$$\text{Varianzas conocidas} \rightarrow \mu_1 - \mu_2 \in \left[\bar{x} - \bar{y} \pm z_{1-\frac{\alpha}{2}} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right]$$

$$\text{Varianzas desconocidas pero iguales } (\sigma^2) \rightarrow \mu_1 - \mu_2 \in \left[\bar{x} - \bar{y} \pm t_{1-\frac{\alpha}{2}, n_1+n_2-2} \cdot S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right]$$

$$\text{Con } S_p = \sqrt{\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}}$$

Intervalo de confianza para la varianza de una normal.

$$\text{Media conocida } (\mu_0) \rightarrow \sigma^2 \in \left[\frac{\sum_{i=1}^n (x_i - \mu_0)^2}{\chi^2_{1-\frac{\alpha}{2}, n}}, \frac{\sum_{i=1}^n (x_i - \mu_0)^2}{\chi^2_{\frac{\alpha}{2}, n}} \right]$$

$$\text{Media desconocida} \rightarrow \sigma^2 \in \left[\frac{(n-1)S^2}{\chi^2_{1-\frac{\alpha}{2}, n-1}}, \frac{(n-1)S^2}{\chi^2_{\frac{\alpha}{2}, n-1}} \right]$$

Intervalo de confianza para el cociente de varianzas de dos poblaciones normales e independientes.

$$\text{Medias conocidas} \rightarrow \frac{\sigma_2^2}{\sigma_1^2} \in \left[\frac{\sum_{i=1}^{n_2} (y_i - \mu_2)^2}{\sum_{i=1}^{n_1} (y_i - \mu_1)^2} \cdot \frac{n_1}{n_2} F_{\frac{\alpha}{2}, n_1, n_2}, \frac{\sum_{i=1}^{n_2} (y_i - \mu_2)^2}{\sum_{i=1}^{n_1} (y_i - \mu_1)^2} \cdot \frac{n_1}{n_2} F_{1-\frac{\alpha}{2}, n_1, n_2} \right]$$

$$\text{Medias desconocidas} \rightarrow \frac{\sigma_2^2}{\sigma_1^2} \in \left[\frac{S_2^2 F_{\frac{\alpha}{2}, n_1-1, n_2-1}}{S_1^2}, \frac{S_2^2 F_{1-\frac{\alpha}{2}, n_1-1, n_2-1}}{S_1^2} \right]$$

9. Intervalos de Confianza para medias, varianzas y proporciones

Intervalo de confianza para una proporción

$$p \in \left[\hat{p} \pm z_{1-\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

Intervalo de confianza para la diferencia de proporciones.

$$p_1 - p_2 \in \left[\hat{p}_1 - \hat{p}_2 \pm z_{1-\frac{\alpha}{2}} \sqrt{\frac{\hat{p}_T(1-\hat{p}_T)}{n_1} + \frac{\hat{p}_T(1-\hat{p}_T)}{n_2}} \right]$$

$$\hat{p}_T = \frac{n_1 \hat{p}_1 + n_2 \hat{p}_2}{n_1 + n_2}$$

EjemPlo:

El hundimiento de un petrolero en las proximidades de la costa de una determinada región ha provocado un gran desastre tanto económico como ecológico. Con el fin de analizar la composición del fuel que desprende el buque, han sido seleccionadas 17 galletas de chapapote sobre las que medir la concentración de cinc, obteniéndose por término medio 140 mg/l, con una desviación típica de 30 mg/l.

- Obtén un intervalo de confianza al 95% para la concentración media de cinc en el fuel que desprende el petrolero.
- ¿Qué ocurriría al incrementar el tamaño de muestra? Razona la respuesta.

9. Intervalos de Confianza para medias, varianzas y proporciones.

EJEMPLO:

Una empresa dedicada al transporte de viajeros en autobús está interesada en determinar el tiempo empleado en realizar un determinado recorrido. La observación de 20 de estos trayectos proporciona una media de 4.05 horas y una desviación típica de 0.08 horas. Con el fin de conocer la variabilidad existente en el tiempo empleado en realizar el trayecto, obtiene un intervalo de confianza al 90%.

EJEMPLO:

En un estudio sobre los préstamos realizados por dos entidades financieras a sus clientes se toma una muestra aleatoria de 10 préstamos concedidos por cada entidad, resultado en los siguientes datos (miles de €):

Entidad 1	57.9	66.2	65.4	65.4	65.2	62.6	67.6	63.7	67.2	71
Entidad 2	66.4	71.7	70.3	69.3	64.8	69.6	68.6	69.4	65.3	68.8

- Obtén un intervalo de confianza al 90% para el cociente de varianzas. ¿Puede suponerse la misma variabilidad en los préstamos concedidos por ambas entidades. Las variables son independientes y todos los parámetros se desconocen.
- Obtén un intervalo de confianza al 95% para la diferencia en las cantidades concedidas en media por ambas entidades. ¿Existen diferencias significativas?