


Tema 6. Contrastes de hipótesis.



Índice.

1. Conceptos básicos.
2. Pasos a seguir para realizar un contraste.
3. Contrastes para medias y varianzas en poblaciones normales.
4. Contrastes de hipótesis para proporciones.
5. Relación entre intervalos de confianza y contrastes de hipótesis.
6. Análisis de la varianza de un factor. ANOVA.
7. Contraste de bondad de ajuste.
 - 7.1. Test Chi-Cuadrado de Pearson de bondad de ajuste.
 - 7.2. Test de Kolmogorov-Smirnov.
8. Tablas de contingencia. Contrastes de asociación entre variables categóricas.
 - 8.1. Test Chi-Cuadrado de Pearson de independencia.
 - 8.2. Test Chi-Cuadrado de Pearson de homogeneidad.
9. Contrastes de aleatoriedad: Test de rachas.

1. Conceptos básicos.

Una **hipótesis estadística** es una afirmación acerca de una característica poblacional formulada en base a los parámetros de su distribución. Hay diversos tipos de hipótesis.

- **Hacen referencia a un parámetro de una población.**

La hipótesis asigna un único valor al parámetro, *hipótesis simple* ($= o \neq$), en el caso de que asigne varios valores, *hipótesis compuesta* ($< o >$).

- **Comparan parámetros de varias poblaciones.**
- **Contrastar una hipótesis.**

Estos significa comparar lo que dice la hipótesis con la información que proporciona la muestra. Si hay coincidencia, dentro del error admisible entre la hipótesis planteada (*Hipótesis nula, H_0*) y la información muestral, entonces no habrá evidencia para rechazarla. En el caso de que no coincida, podremos rechazar la hipótesis nula y, por tanto, aceptaremos otra hipótesis (*Hipótesis alternativa, H_1*).

Nunca podemos afirmar que una hipótesis sea verdadera o falsa, por lo que al realizar un contraste y tomar una decisión hay una posibilidad de equivocarnos. Esta posibilidad se divide en dos tipos de errores, ambos asociados a cualquier contraste.

- **Error Tipo I (nivel de confianza):** Posibilidad de rechazar H_0 siendo esta cierta. Este error se denotará con α .
- **Error Tipo II (potencia del test):** Posibilidad de aceptar H_0 siendo esta falsa. Este error se denotará con β .

Cuando aumenta un error, disminuye el otro.

	H_0 es cierta	H_0 es falsa
Aceptamos H_0	No hay error	Error tipo II
Rechazamos H_0	Error tipo I	No hay error

2. Pasos a seguir para realizar un contraste.

1. Planteamos la hipótesis nula (H_0) y la alternativa (H_1)

La hipótesis nula debe ser de tipo igualdad y la alternativa a favor de la información muestral.

$$H_0: \theta = \theta_0$$

$$H_1: \theta \neq \theta_0$$

$$\theta < \theta_0$$

$$\theta > \theta_0$$

2. Fijamos el nivel de significación (α).

Normalmente se suelen fijar en 0.05, 0.01 ó 0.1.

3. Determinar una medida de discrepancia entre la hipótesis nula y la información muestral.

Esta medida estará en función de la diferencia del valor que especifica H_0 para el parámetro y el estimador muestral del parámetro, y tendrá distribución conocida. A tal medida se le llama **estadístico de contraste bajo H_0** .

4. Determinar la discrepancia máxima que estamos dispuestos a admitir para aceptar H_0 .

Este valor dependerá de la distribución del estadístico de contraste bajo H_0 , del nivel de significación especificado y del tipo de hipótesis alternativa que tengamos. Delimita las regiones de aceptación y rechazo de H_0 .

5. Conclusión.

Si el estadístico de contraste observado cae en el región de rechazo, rechazamos H_0 , en caso contrario, se mantiene como cierta.

2. Pasos a seguir para realizar un contraste.

EJEMPLO 1:

Sea $X \rightarrow N(\mu, \sigma)$ con μ, σ desconocidas, y sobre μ plateamos el siguiente contraste:

$$H_0: \mu = 90$$

$$H_1: \mu > 90$$

Seleccionamos una muestra de tamaño n y el estadístico de contraste bajo H_0 (suponiendo H_0 cierta) es:

$$T = \frac{\bar{X} - 90}{\frac{S}{\sqrt{n}}} \rightarrow t_{n-1}$$

Suponiendo que tenemos una muestra de tamaño 20 que nos proporciona una media de 98 y una desviación típica de 2'21. ¿Cuál es el estadístico observado?

EJEMPLO 2:

Sobre el ejemplo anterior, consideramos ahora la hipótesis alternativa $H_1: \mu < 90$

$$H_0: \mu = 90$$

$$H_1: \mu < 90$$

EJEMPLO 3:

Ahora consideramos que la hipótesis alternativa $H_1: \mu \neq 90$

3. Contrastes para medias y varianzas en poblaciones normales.

Contraste para la media de una población normal con varianza conocida

Hipótesis nula	Estadístico de contraste
$H_0 : \mu = \mu_0$	$Z = \frac{X - \mu_0}{\sigma/\sqrt{n}}$
Hipótesis alternativa	Criterios de rechazo
$H_1 : \mu \neq \mu_0$	$Z \leq z_{\alpha/2} \text{ o } Z \geq z_{1-\alpha/2}$
$H_1 : \mu > \mu_0$	$Z \geq z_{1-\alpha}$
$H_1 : \mu < \mu_0$	$Z \leq z_{\alpha}$

EJEMPLO:

Analizadas las cifras de devoluciones correspondientes a artículos comprados online en una cadena de grandes almacenes, se observa que el importe de las devoluciones se distribuye normalmente con una desviación típica de 2€. En tienda, las devoluciones presentan una media de 50€. Una muestra aleatoria de 25 devoluciones tras compra online proporciona una media de 53'1€. Contrastar al 5% de significación si la cantidad media por devolución tras compra online es significativamente distinta de la cantidad media por devolución en la tienda.

3. Contrastes para medias y varianzas en poblaciones normales.

Contraste para la media de una población normal con varianza desconocida

Hipótesis nula	Estadístico de contraste
$H_0 : \mu = \mu_0$	$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$
Hipótesis alternativa	Criterios de rechazo
$H_1 : \mu \neq \mu_0$	$T \leq t_{\alpha/2, n-1}$ o $T \geq t_{1-\alpha/2, n-1}$
$H_1 : \mu > \mu_0$	$T \geq t_{1-\alpha, n-1}$
$H_1 : \mu < \mu_0$	$T \leq t_{\alpha, n-1}$

EJEMPLO:

La cotización (en euros) de una acción durante 22 días son los siguientes: 19'8, 18'5, 17'6, 16'7, 15'8, 15'4, 14'1, 13'6, 11'9, 11'4, 11'4, 8'8, 7'5, 15'4, 15'4, 19'5, 14'9, 12'7, 11'9, 11'4, 10'1, 7'9.

¿Sugieren los datos que la cotización diaria es superior a 10€? Realizar el contraste a un 10% de significación.

3. Contrastes para medias y varianzas en poblaciones normales.

Contraste para la varianza de una población normal con media conocida

Hipótesis nula	Estadístico de contraste
$H_0 : \sigma^2 = \sigma_0^2$	$\chi^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{\sigma_0^2}$
Hipótesis alternativa	Criterios de rechazo
$H_1 : \sigma^2 \neq \sigma_0^2$	$\chi^2 \leq \chi_{\alpha/2,n}^2$ o $\chi^2 \geq \chi_{1-\alpha/2,n}^2$
$H_1 : \sigma^2 > \sigma_0^2$	$\chi^2 \geq \chi_{1-\alpha,n}^2$
$H_1 : \sigma^2 < \sigma_0^2$	$\chi^2 \leq \chi_{\alpha,n}^2$

Contraste para la varianza de una población normal con media desconocida

Hipótesis nula	Estadístico de contraste
$H_0 : \sigma^2 = \sigma_0^2$	$\chi^2 = \frac{(n-1) S^2}{\sigma_0^2}$
Hipótesis alternativa	Criterios de rechazo
$H_1 : \sigma^2 \neq \sigma_0^2$	$\chi^2 \leq \chi_{\alpha/2,n-1}^2$ o $\chi^2 \geq \chi_{1-\alpha/2,n-1}^2$
$H_1 : \sigma^2 > \sigma_0^2$	$\chi^2 \geq \chi_{1-\alpha,n-1}^2$
$H_1 : \sigma^2 < \sigma_0^2$	$\chi^2 \leq \chi_{\alpha,n-1}^2$

EJEMPLO:

Un fabricante de detergente líquido está interesado en la uniformidad de la máquina que utiliza para llenar las botellas. DE manera específica, es deseable que la varianza del proceso de llenado sea menor que 0'01, de otro modo existe un porcentaje mauor que el deseable de botellas con un contenido menor de detergente. Supóngase que la distribución del volumen de llenado es aproximadamente Normal. Al tomar una muestra aleatoria de 20 botellas se obtiene una varianza muestral de 0'0153. ¿Tiene el fabricante problemas en el proceso de llenado de las botellas? Realizar el contraste al 5% de significación.

3. Contrastes para medias y varianzas en poblaciones normales.

Contraste para el cociente de varianzas de dos poblaciones independientes con medias conocidas

Hipótesis nula	Estadístico de contraste
$H_0 : \sigma_1^2 = \sigma_2^2$	$F = \frac{\sum_{i=1}^{n_1} (x_i - \mu_1)^2 / n_1}{\sum_{i=1}^{n_2} (y_i - \mu_2)^2 / n_2}$
Hipótesis alternativa	Criterios de rechazo
$H_1 : \sigma_1^2 \neq \sigma_2^2$	$F \leq 1/f_{1-\alpha/2, n_2, n_1} \text{ o } F \geq f_{1-\alpha/2, n_1, n_2}$
$H_1 : \sigma_1^2 > \sigma_2^2$	$F \geq f_{1-\alpha, n_1, n_2}$
$H_1 : \sigma_1^2 < \sigma_2^2$	$F \leq 1/f_{1-\alpha, n_2, n_1}$

Contraste para el cociente de varianzas de dos poblaciones independientes con medias desconocidas

Hipótesis nula	Estadístico de contraste
$H_0 : \sigma_1^2 = \sigma_2^2$	$F = \frac{S_1^2}{S_2^2}$
Hipótesis alternativa	Criterios de rechazo
$H_1 : \sigma_1^2 \neq \sigma_2^2$	$F \leq 1/f_{1-\alpha/2, n_2-1, n_1-1} \text{ o } F \geq f_{1-\alpha/2, n_1-1, n_2-1}$
$H_1 : \sigma_1^2 > \sigma_2^2$	$F \geq f_{1-\alpha, n_1-1, n_2-1}$
$H_1 : \sigma_1^2 < \sigma_2^2$	$F \leq 1/f_{1-\alpha, n_2-1, n_1-1}$

3. Contrastes para medias y varianzas en poblaciones normales.

Contraste para la diferencia de medias de dos poblaciones normales independientes con varianzas conocidas

Hipótesis nula	Estadístico de contraste
$H_0 : \mu_1 - \mu_2 = \delta_0$	$Z = \frac{X - Y - \delta_0}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$
Hipótesis alternativa	Criterios de rechazo
$H_1 : \mu_1 - \mu_2 \neq \delta_0$	$Z \leq z_{\alpha/2} \text{ o } Z \geq z_{1-\alpha/2}$
$H_1 : \mu_1 - \mu_2 > \delta_0$	$Z \geq z_{1-\alpha}$
$H_1 : \mu_1 - \mu_2 < \delta_0$	$Z \leq z_{\alpha}$

Contraste para la diferencia de medias de dos normales independientes con varianzas desconocidas pero iguales.

Hipótesis nula	Estadístico de contraste
$H_0 : \mu_1 - \mu_2 = \delta_0$	$T = \frac{X - Y - \delta_0}{\sqrt{S_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$
Hipótesis alternativa	Criterios de rechazo
$H_1 : \mu_1 - \mu_2 \neq \delta_0$	$T \leq t_{\alpha/2, n} \text{ o } T \geq t_{1-\alpha/2, n}$
$H_1 : \mu_1 - \mu_2 > \delta_0$	$T \geq t_{1-\alpha, n}$
$H_1 : \mu_1 - \mu_2 < \delta_0$	$T \leq t_{\alpha, n}$

$$n = n_1 + n_2 - 2$$

$$S_p^2 = \frac{(n_1 - 1) S_1^2 + (n_2 - 1) S_2^2}{n}$$

3. Contrastes para medias y varianzas en poblaciones normales.

Contraste para la diferencia de medias de dos poblaciones normales independientes con varianzas conocidas

Contraste para la diferencia de medias de dos normales independientes con varianzas desconocidas pero iguales.

EJEMPLO:

Una planta dedicada al montaje de grandes motores industriales ha puesto en funcionamiento un nuevo sistema de montaje. Con el fin de conocer si el tiempo medio de montaje es menor con este nuevo sistema, se seleccionan dos muestras aleatorias de tamaño 8 de cada uno de los tipos de montaje, resultando los tiempos en horas invertidos dados en la tabla.

Nuevo	Antiguo
91.5	89.19
94.18	90.95
92.18	90.46
95.39	93.21
91.79	97.19
89.07	97.04
94.72	91.07
89.21	92.75

- a) Contrastar al 10% de significación si difiere la variabilidad del tiempo invertido en ambos sistemas de montaje.
- b) Contrastar al 5% si interesa emplear el nuevo sistema de montaje.

3. Contrastes para medias y varianzas en poblaciones normales.

Contraste para la diferencia de medias de dos normales relacionadas (muestras apareadas) con varianzas desconocidas pero iguales.

Hipótesis nula	Estadístico de contraste
$H_0 : \mu_1 - \mu_2 = \delta_0$	$T = \frac{D - \delta_0}{\sqrt{\frac{S_D^2}{n}}}$
Hipótesis alternativa	Criterios de rechazo
$H_1 : \mu_1 - \mu_2 \neq \delta_0$	$T \leq t_{\alpha/2, n-1}$ o $T \geq t_{1-\alpha/2, n-1}$
$H_1 : \mu_1 - \mu_2 > \delta_0$	$T \geq t_{1-\alpha, n-1}$
$H_1 : \mu_1 - \mu_2 < \delta_0$	$T \leq t_{\alpha, n-1}$

donde $D = X - Y$.

EJEMPLO:

Un anuncio publicitario presenta un nuevo aparato de gimnasia cuyo uso durante una semana reduce el peso considerablemente, asegura que la reducción de peso es al menos de 200 gramos. Se tomó una muestra aleatoria de 9 personas y se les ofreció probar gratuitamente el producto durante una semana. Los pesos, en Kg. de estas personas antes y después de la prueba fueron los siguientes.

Antes (X)	90.186	71.151	84.322	88.339	95.2	74.402	79.365	75.537	93.559
Después (Y)	90.061	70.992	84.063	88.062	95.065	74.178	79.037	75.086	93.052

Contrastar al 5% de significación si hay diferencia en el peso tras el uso del aparato, y en tal caso, si la reducción del peso es significativamente superior a 200 gramos.

4. Contrastes de hipótesis para proporciones.

Contraste de hipótesis para una proporción poblacional.

Hipótesis nula	Estadístico de contraste
$H_0 : p = p_0$	$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$
Hipótesis alternativa	Criterios de rechazo
$H_1 : p \neq p_0$	$Z \leq z_{\alpha/2} \text{ o } Z \geq z_{1-\alpha/2}$
$H_1 : p > p_0$	$Z \geq z_{1-\alpha}$
$H_1 : p < p_0$	$Z \leq z_{\alpha}$

EJEMPLO:

Un distribuidor adquirirá un lote de equipos si el porcentaje de defectuosos no es mayor que el 3%, y se quiere una probabilidad del 5% de rechazar la compra aunque verifique la condición requerida. Prueba 30 equipos y 2 de ellos resultan defectuosos. ¿Qué decisión debe adoptar?

4. Contrastes de hipótesis para proporciones.

Contraste de hipótesis para la comparación de dos proporciones poblacionales.

Hipótesis nula	Estadístico de contraste
$H_0 : p_1 = p_2$	$Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}_T (1 - \hat{p}_T) / n_1 + \hat{p}_T (1 - \hat{p}_T) / n_2}}$
Hipótesis alternativa	Criterios de rechazo
$H_1 : p_1 \neq p_2$	$Z \leq z_{\alpha/2} \text{ o } Z \geq z_{1-\alpha/2}$
$H_1 : p_1 > p_2$	$Z \geq z_{1-\alpha}$
$H_1 : p_1 < p_2$	$Z \leq z_{\alpha}$

$$\hat{p}_T = \frac{n_1 \hat{p}_1 + n_2 \hat{p}_2}{n_1 + n_2}$$

EJEMPLO:

Una central de productos lácteos recibe diariamente la leche de dos granjas A y B. Con el fin de estudiar la calidad de los productos recibidos se extraen dos muestras, una de cada granja, y se analiza el contenido de materia grasa de cada producto. Se obtienen los siguientes resultados:

Granja A	0.32	0.29	0.30	0.28	0.33	0.31	0.30	0.29	0.33	0.32	0.30	0.29		
Granja B	0.28	0.30	0.33	0.29	0.31	0.29	0.33	0.32	0.29	0.32	0.31	0.32	0.29	0.33

Si la central rechaza aquellos productos con un contenido graso superior a 0'32, ¿existen diferencias significativas entre los porcentajes de productos A y B que se tendrían que rechazar? Realizar el contraste al 5% de significación.

5. Relación entre intervalos de confianza y contrastes de hipótesis.

Hay una estrecha relación entre el contraste de hipótesis sobre un parámetro y el intervalo de confianza sobre este mismo.

Si tenemos un intervalo de confianza a un nivel de confianza de $1-\alpha$, entonces el contraste bilateral (dos colas)

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta \neq \theta_0$$

a un nivel de significación α conduce a rechazar la hipótesis nula si el estimador no pertenece a dicho intervalo.

6. Análisis de la varianza de un factor (ANOVA).

En algunas ocasiones tendremos la necesidad de comparar más de dos medias para detectar diferencias significativas entre ellas en cuanto a una variable.

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_I$$

$$H_1 : \text{Existe alguna distinta}$$

siendo I el **número de poblaciones**.

El **análisis de la varianza (ANOVA)** es un procedimiento creado por Fisher en 1925 para descomponer la variabilidad de un experimento en componentes independientes que puedan asignarse a causas distintas.

En este tipo de análisis vamos a tener un **factor** (ejemplo: alumnos de distintas clase) del que observaremos una **característica continua** que varía de un individuo a otro, a esto lo denominaremos **variable respuesta** (ejemplo: Notas de estadística de los alumnos).

El **objetivo** principal es conocer si existe o no relación entre la variable respuesta y el factor (ejemplo: ¿habrá diferencia entre las notas de clase de los alumnos de los distintos grupos de estadística?)

6. Análisis de la varianza de un factor (ANOVA).

El modelo.

Se ajustan las observaciones a un modelo matemático con la siguiente forma $y_{ij} = \mu_i + u_{ij}$, esto nos ayudará a poder tratar las observaciones de forma estadística.

$\mu_i \rightarrow$ media de las observaciones

Este modelo se divide en los siguientes parámetros: $y_{ij} \rightarrow$ observaciones

$u_{ij} \rightarrow$ error experimental o perturbación

HIPÓTESIS DEL MODELO:

- $E(u_{ij}) = 0 \forall i, j$ o $E(y_{ij}) = \mu_i$
- $Var(u_{ij}) = \sigma^2 \forall i, j$ (homoscedasticidad)
- $E(u_{ij}u_{rk}) = 0 \forall i \neq r, j \neq k$ (incorrelación)
- $u_{ij} \rightarrow N(0, \sigma^2)$ o $y_{ij} \rightarrow N(\mu_i, \sigma^2)$ (normalidad)

Los dos últimos puntos implican independencia

ESTIMACIÓN DE LOS PARÁMETROS DEL MODELO:

Para ello utilizamos el método de máxima verosimilitud.

$$\hat{\mu}_i = \bar{y}_{i.} = \frac{\sum_{j=1}^{n_i} y_{ij}}{n_i}, i = 1, \dots, I$$

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^I \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2}{n}$$

- Los residuos se calculan $\rightarrow \hat{u}_{ij} = e_{ij} = y_{ij} - \bar{y}_{i.}$

CONTRASTE DE IGUALDAD DE MEDIAS:

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_I$$

H_1 : Existe alguna distinta

6. Análisis de la varianza de un factor (ANOVA).

Descomposición de la variabilidad.

Como ya sabemos, el análisis de la varianza es un procedimiento para descomponer la variabilidad total presente en un experimento en componentes independientes que puedan asignarse a causas distintas. Con esto, según el modelo se llega a que la variabilidad total en el experimento es igual a la suma de la variabilidad existente dentro de los grupos más la variabilidad existente entre los grupos.

$$y_{ij} - \bar{y}_{..} = (\bar{y}_{i.} - \bar{y}_{..}) + (y_{ij} - \bar{y}_{i.})$$

$$\sum_i \sum_j (\bar{y}_{ij} - \bar{y}_{..})^2 = \sum_i n_i (\bar{y}_{i.} - \bar{y}_{..})^2 + \sum_i \sum_j e_{ij}^2 \rightarrow VT = VE + VNE$$

VT : Variabilidad total

VE : Variabilidad explicada por el modelo; variabilidad entre grupos

VNE : Variabilidad no explicada por el modelo, o residual; variabilidad dentro de los grupos

$R^2 = \frac{VE}{VT}$ → Esta medida indica la variabilidad que explica el modelo de entre toda la presente en el experimento, debe de estar entre los valores 0 y 1.

Un valor próximo a 0 indicaría que el modelo no es válido.

6. Análisis de la varianza de un factor (ANOVA).

Tabla ANOVA. Contraste de la F.

El contraste básico del análisis de la varianza utiliza la descomposición de la variabilidad $VT=VE+VNE$.

- Tabla ANOVA:

Fuentes de variabilidad

S. Cuadrados

G. Libertad

Varianza

Entre grupos (VE)

$$VE = \sum_i n_i (\bar{y}_{i\cdot} - \bar{y}_{\cdot\cdot})^2$$

$I - 1$

$$\widehat{S}_e^2 = \frac{VE}{I - 1}$$

Dentro de grupos (VNE)

$$VNE = \sum_i \sum_j e_{ij}^2 = \sum_i n_i \sigma_{n_i}^2$$

$n - I$

$$\widehat{S}_R^2 = \frac{VNE}{n - I}$$

Total (VT)

$$VT = \sum_i \sum_j (y_{ij} - \bar{y}_{\cdot\cdot})^2 = n \sigma_n^2$$

$n - 1$

$$\widehat{S}_y^2 = \frac{VT}{n - 1}$$

- Contraste de la F:

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_I$$

$$H_1 : \text{Alguna distinta}$$

El estadístico de contraste (bajo H_0) es:

$$F = \frac{\widehat{S}_e^2}{\widehat{S}_R^2} \rightarrow F_{I-1, n-I}$$

Rechazamos H_0 cuando $F > F_{1-\alpha, I-1, n-I}$. En este caso, podremos decir que no se han detectado diferencias significativas entre los grupos en cuanto a la variable respuesta.

6. Análisis de la varianza de un factor (ANOVA).

Tabla ANOVA. Contraste de la F.

EJEMPLO:

Se desea comparar el número de ventas mensuales de coches de tres marcas distintas (A, B y C). Con tal fin, se seleccionan aleatoriamente cuatro concesionarios de venta de cada marca en los que se recogen las siguientes ventas mensuales.

Tipo de marca	Ventas mensuales			
A	143	141	150	146
B	152	149	137	143
C	134	133	132	127

Contrastar con un nivel de significación del 5% si difieren las ventas mensuales según las marcas. Se supone que las muestras proceden de poblaciones normales e independientes con la misma varianza.

6. Análisis de la varianza de un factor (ANOVA).

Comprobación de las hipótesis previas al modelo.

La hipótesis de partida del modelo (aleatoriedad, independencia, normalidad, igualdad de varianzas) son esenciales para la correcta aplicación del contraste del ANOVA.

La falta de normalidad en los datos es la que menos influencia tiene en el contraste, sobre todo si los tamaños muestrales son suficientemente grandes, ya que en tal caso, las medias muestrales tendrán una distribución aproximada a la normal, en virtud del Teorema Central del Límite. Aún existen test para contrastar la normalidad en los datos, el más utilizado es el **test de bondad ajuste de Kolmogorov -Smirnov**.

En cuanto a la igualdad de las varianzas poblacionales (**homocedasticidad**), de no cumplirse esta hipótesis, la región crítica tiende a aumentar considerablemente, con lo que el test ANOVA siempre tiende a rechazar la hipótesis nula. Este efecto negativo puede minimizarse utilizando muestras de igual tamaño. En cualquier caso, existen diversos test para contrastar la igualdad de las varianzas de más de dos poblaciones, **test de Bartlett**.

7. Contrastes de bondad de ajuste.

Test Chi-Cuadrado de bondad de ajuste.

Considerando una muestra aleatoria de tamaño n de una variable aleatoria X que se divide en k clases exhaustivas y mutuamente excluyentes. Se plantea el siguiente contraste.

$$H_0 : F(x) = F_0(x)$$

$$H_1 : F(x) \neq F_0(x)$$

Sea p_i la probabilidad de obtener una observación en la i -ésima clase bajo la hipótesis H_0 , de tal forma que su sumatoria sea 1, encontramos el siguiente estadístico.

$$\chi^2_{\text{exp}} = \sum_{i=1}^k \frac{(n_i - E_i)^2}{E_i} = \frac{(n_i - np_i)^2}{np_i}$$

Con el siguiente criterio de rechazo.

$$\text{Se rechaza } H_0 \text{ si } \chi^2_{\text{exp}} \geq \chi^2_{k-1; 1-\alpha}$$

Observaciones:

- Se emplea principalmente con datos de una distribución discreta. También en variables continuas cuando están agrupadas por intervalos.
- El tamaño de la muestra n debe ser aproximadamente cinco veces el número de clases ($n > 5k$)
- Es aconsejable que $np_i > 5$ y nunca < 1 , en este último caso se agrupan clases contiguas.

EJEMPLO:

Se presenta a continuación una muestra de tiempos entre llegadas (en horas) de clientes a un banco, junto con sus frecuencias observadas. Se desea contrastar al 5% de significación, si dichos tiempos proceden de dicha distribución geométrica.

x_i	0	1	2	3	4	5	6
n_i	42	28	13	5	7	3	2

La distribución es discreta y presenta la siguiente función masa de probabilidad.

$$P(X=x)=p(1-p)^x, \quad x=0,1,2,3,\dots$$

7. Contrastes de bondad de ajuste.

Test de Kolmogorov-Smirnov.

Para funciones continuas y con muestra disponible de tamaño pequeño, utilizaremos el test de Kolmogorov-Smirnov, ya que no necesita que sus datos estén agrupados.

El contraste se basa en la comparación de la distribución empírica y la función de distribución bajo la hipótesis nula.

Considerando el siguiente contraste:

$$H_0 : F(x) = F_0(x)$$

$$H_1 : F(x) \neq F_0(x)$$

El estadístico de Kolmogorov-Smirnov se define como:

$$D_{\text{exp}} = \max_{1 \leq i \leq n} \{ |F_n(x_{(i-1)}) - F_0(x_{(i)})|, |F_n(x_{(i)}) - F_0(x_{(i)})| \}$$

Donde la función empírica y el criterio de rechazo son:

$$F_n(x_{(i)}) = \begin{cases} 0 & x_{(i)} < x_{(1)} \\ 1/n & x_{(1)} \leq x_{(i)} \leq x_{(2)} \\ \vdots & \vdots \\ k/n & x_{(k)} \leq x_{(i)} \leq x_{(k+1)} \\ \vdots & \vdots \\ 1 & x_{(i)} \geq x_{(n)} \end{cases}$$

Rechazamos H_0 si el estadístico muestral D_{exp} es mayor que el valor teórico $D_{n,1-\alpha}$, que aparece en la tabla dada para este contraste.

Ejemplo: Una compañía dedicada al envasado y comercialización de un producto de alimentación, pretende realizar un estudio sobre la presencia de cierta sustancia química que, en niveles altos, podría ser perjudicial para la salud. Los niveles de dicha sustancia correspondientes a una muestra se recogen en la siguiente tabla. Nos planteamos, al 5% de significación, si dichos datos pueden proceder de una distribución exponencial.

1.46	0.49	0.72	0.11	0.27	0.78	3.98	0.19	0.81	0.48
0.23	0.08	0.30	1.73	0.90	0.06	0.08	0.89	0.11	0.05

8. Tablas de contingencia. Contrastes de asociación entre variables categóricas.

Test Chi-cuadrado de Pearson de independencia.

Este tipo de contraste se utiliza para saber si hay relación entre dos características diferentes estudiadas en una misma población.

La hipótesis que se busca contrastar es la independencia de ambos caracteres, donde se desea saber si hay una diferencia suficientemente significativa entre las frecuencias que se observan y las que se esperan bajo la hipótesis de independencia.

Para ello nos encontramos con las **tablas de contingencia** con dos criterios de clasificación, esta tabla se representa de la siguiente forma:

A/B	1	2	...	j	...	l	$n_{i.}$
1	n_{11}	n_{12}		n_{1j}		n_{1l}	$n_{1.}$
2	n_{21}	n_{22}		n_{2j}		n_{2l}	$n_{2.}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
i	n_{i1}	n_{i2}		n_{ij}		n_{il}	$n_{i.}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
k	n_{k1}	n_{k2}		n_{kj}		n_{kl}	$n_{k.}$
$n_{.j}$	$n_{.1}$	$n_{.2}$		$n_{.j}$		$n_{.l}$	$n_{..}$

Si las dos características A y B son independientes, la probabilidad conjunta debe ser igual al producto de las marginales, de esta forma podemos establecer la hipótesis nula:

$$H_0 : A \text{ y } B \text{ son independientes.}$$

$$H_1 : A \text{ y } B \text{ no son independientes.}$$

o equivalentemente,

$$H_0 : p_{ij} = p_{i.} p_{.j} \text{ para todo } i, j$$

$$H_1 : p_{ij} \neq p_{i.} p_{.j} \text{ para algún } i \neq j$$

En la mayoría de aplicaciones, las probabilidades marginales no se conocen y deben estimarse mediante sus estimadores máximo verosímiles (EMV), que son:

$$\hat{p}_{i.} = \frac{n_{i.}}{n}$$

$$\hat{p}_{.j} = \frac{n_{.j}}{n}$$

Por lo que el **estadístico de contraste** que se utiliza es el siguiente:

$$\chi^2_{exp} = \sum_{i=1}^k \sum_{j=1}^l \frac{(n_{ij} - \hat{p}_{i.} \hat{p}_{.j} n)^2}{\hat{p}_{i.} \hat{p}_{.j} n} = \sum_{i=1}^k \sum_{j=1}^l \frac{(n_{ij} - \frac{n_{i.} n_{.j}}{n})^2}{\frac{n_{i.} n_{.j}}{n}} \rightarrow \chi^2_{(k-1)(l-1)}$$

8. Tablas de contingencia. Contrastes de asociación entre variables categóricas.

Test Chi-cuadrado de Pearson de independencia.

El criterio de rechazo y el p-valor son los siguientes:

La región crítica es la siguiente:

$$\text{Se rechaza } H_0 \text{ si } \chi_{\text{exp}}^2 \geq \chi_{(k-1)(l-1); 1-\alpha}^2$$

El p-valor se calcula de la siguiente forma.

$$p\text{-valor} = P\left(\chi_{(k-1)(l-1)}^2 > \chi_{\text{exp}}^2\right)$$

Ejemplo: Se desea realizar un estudio sobre las agencias inmobiliarias para determinar si existe o no relación entre el tamaño de las mismas (según número de empleados) y la existencia de un plan de marketing. Con tal fin, se considera una muestra de 91 agencias inmobiliarias y se clasifican según el número de empleados y la existencia o no de un plan de marketing:

Plan marketing \ N° de empleados	<100	100-500	>500	Total
Sí	13	18	32	63
No	10	12	6	28
Total	23	30	36	91

Contrastar al 5% de significación si existe relación entre el tamaño de la agencia inmobiliaria y la existencia de un plan de marketing.

Calificación:

8. Tablas de contingencia. Contrastes de asociación entre variables categóricas.

Test Chi-cuadrado de Pearson de homogeneidad

Suponemos que queremos analizar r poblaciones, estudiadas respecto a una misma característica C que se puede clasificar en k modalidades.

Para esto obtenemos la siguiente tabla:

Modalidades/Muestras	M_1	M_2	...	M_j	...	M_r	$n_{i.}$
C_1	n_{11}	n_{12}		n_{1j}		n_{1r}	$n_{1.}$
C_2	n_{21}	n_{22}		n_{2j}		n_{2r}	$n_{2.}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
C_i	n_{i1}	n_{i2}		n_{ij}		n_{ir}	$n_{i.}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
C_k	n_{k1}	n_{k2}		n_{kj}		n_{kr}	$n_{k.}$
$n_{.j}$	$n_{.1}$	$n_{.2}$		$n_{.j}$		$n_{.r}$	n

siendo n_{ij} el número de individuos de la j - ésima población observados (de la muestra M_j) que presenta la modalidad i - ésima de la característica C .

La hipótesis nula que se plantea es la siguiente:

$$H_0: p_{i1} = p_{i2} = \dots = p_{ir} = p_{i.} \text{ para } i = 1, \dots, k$$

$$H_1: p_{il} \neq p_{im} \text{ para algún } l \neq m$$

donde $p_{i.}$ es la proporción total de individuos de la i - ésima modalidad, $i = 1, \dots, k$, y p_{ij} es la proporción de individuos de la j - ésima población que presentan la i - ésima modalidad.

En la práctica, los valores $p_{i.}$ no se conocen y deben estimarse:

$$\hat{p}_{i.} = \frac{n_{i.}}{n}, \quad i = 1, \dots, k$$

El estadístico de contraste es:

$$\chi^2_{\text{exp}} = \sum_{i=1}^k \sum_{j=1}^r \frac{(n_{ij} - n_{i.} \hat{p}_{j.})^2}{n_{i.} \hat{p}_{j.}} = \sum_{i=1}^k \sum_{j=1}^r \frac{(n_{ij} - \frac{n_{i.} n_{.j}}{n})^2}{\frac{n_{i.} n_{.j}}{n}} \rightarrow \chi^2_{(k-1)(r-1)}$$

La región crítica es:

$$\text{Se rechaza } H_0 \text{ si } \chi^2_{\text{exp}} \geq \chi^2_{(k-1)(r-1); 1-\alpha}$$

El **p-valor** se calcula de la siguiente forma:

$$p\text{-valor} = P\left(\chi^2_{(k-1)(r-1)} > \chi^2_{\text{exp}}\right)$$

8. Tablas de contingencia. Contrastes de asociación entre variables categóricas.

Ejemplo: Se está realizando un estudio para conocer la actitud de los ciudadanos frente a las campañas publicitarias de la Dirección General de Tráfico. Para ello se dividió la población en tres grupos de edades y, en cada uno, se tomó una muestra aleatoria de ciudadanos a los que se les solicitó elegir entre las siguientes actitudes:.

A: las campañas deberían ser más dramáticas.

B: las campañas deberían ser menos dramáticas.

C: las campañas deberían mantener el nivel de dramatismo actual.

Los resultados fueron los siguientes:

Opinión\Edad	16-30	31-45	Más de 45	Total
A	10	20	10	40
B	60	60	70	190
C	20	20	30	70
Total	90	100	110	300

Contrastar, al 5% de significación, si existen diferencias en las actitudes de los grupos de edad frente al dramatismo de las campañas publicitarias de la DGT.

9. Contraste de aleatoriedad: Test de rachas.

Con este test, contrastaremos la aleatoriedad de una secuencia de eventos a partir del número de rachas **R** de la misma.

Nos encontramos con varios métodos para la construcción de rachas a partir de los datos muestrales:

- **Método 1:** Se considera el primer valor observado y se asigna un signo positivo a un valor de la variable si la diferencia de cada valor con el anterior es positiva, y un signo negativo si es negativa.
- **Método 2:** Se calcula la mediana de las observaciones y se asigna a cada observación un signo positivo a los valores superiores a la mediana, y un signo negativo a los valores inferiores a la mediana y se eliminan los valores iguales a la mediana.

Utilizando cualquiera de los dos métodos anteriores, se calcula:

n^+ = nº de signos positivos

n^- = nº de signos negativos

R = nº de rachas

$$Z_{\text{exp}} = \frac{R - E[R]}{\sqrt{\text{Var}[R]}} \rightarrow N(0, 1)$$

donde

$$E[R] = \frac{2n^+n^-}{n} + 1,$$
$$\text{Var}[R] = \frac{2n^+n^-(2n^+n^- - n)}{n^2(n-1)},$$

con $n = n^+ + n^-$.

Se rechaza H_0 de aleatoriedad si $Z_{\text{exp}} \notin (Z_{\alpha/2}, Z_{1-\alpha/2})$.

Para resolver el contraste tenemos en cuenta que::

- **Si $n^+, n^- < 20$** , los valores críticos aparecen en la tabla del test de rachas.

El estadístico de contraste R se compara con los valores extremos de la tabla y si está entre ellos diremos que no hay evidencia para rechazar la hipótesis nula, y, por lo tanto, admitiremos la hipótesis de aleatoriedad de las observaciones. En otro caso, se rechaza dicha hipótesis.

- **En el caso en que los valores n^+, n^- sean mayores que 20**, se utiliza la primera aproximación a la normal.

9. Contraste de aleatoriedad: Test de rachas.

EJEMPLO:

Supongamos que a lo largo de un mes se han observado en 26 instantes de tiempo la cotización de un determinado valor en bolsa, teniendo los siguientes valores:

1.8	2.4	1.9	3.2	2.8	2.1	2.3	1.8	1.7	2	2.8	3	2.4
1.8	3.5	2.6	2.1	1.9	2.9	2.7	1.8	2.6	1.8	2.1	2.3	2.4

Para un nivel de significación del 1%, ¿se puede decir que estas observaciones constituyen una muestra aleatoria?

EJEMPLO

En un proceso de producción de un determinado tipo de piezas, se producen piezas buenas y defectuosas. Si seleccionamos una muestra de 18 piezas fabricadas por la misma máquina durante un día, las piezas que fueron buenas y las que fueron defectuosas aparecieron en el siguiente orden.

DDDBBBDDDBBBBDDBBB

Para un nivel de significación del 5%, ¿se puede concluir que las piezas buenas y defectuosas aparecen aleatoriamente?