



Tema 7. Regresión Lineal Simple.



Índice

1. Introducción.
2. El modelo de regresión lineal,
3. Estimación de los parámetros del modelo.
4. Inferencias sobre el coeficiente de regresión.
5. El coeficiente de correlación lineal y el coeficiente de determinación.
6. Predicción a partir del modelo.
7. Diagnóstico del modelo.
 - a. Normalidad de los residuos.
 - b. Gráfica de residuos frente a valores ajustados.

1. Introducción.

Uno de los aspectos más relevantes de la Estadística es el análisis de la relación o dependencia entre variables.

Frecuentemente resulta de interés conocer el efecto que una o varias variables pueden causar sobre otra, e incluso predecir valores en una variable a partir de otra.

- Los **métodos de regresión** estudian la construcción de modelos para explicar o representar la dependencia entre una variable Y y una serie de variables $X_1, X_2, \dots, X_n$. En la que la variable Y es la **variable explicada, dependiente**, etc. y las variables X son las **variables explicativas, independientes**, etc.
- Si asumimos que dichas variables explicativas influyen sobre la variable explicada, podrían existir otros factores o variables que no controlamos y que también pueden influir sobre dicha variables, a estos factores los denominamos **perturbación**.

Por lo tanto, el objetivo será buscar una función g, que permita expresar la dependencia entre las variables. En el caso de que la dependencia sea de tipo lineal y con varias variables explicativas, al modelo se le llama **modelo de regresión lineal múltiple**. En el caso de que solo haya una variable explicativa, le llamaremos **modelo de regresión lineal simple**.

EJEMPLO:

Supongamos que la altura de los padres influye significativamente en la de los hijos:

- Probablemente la dependencia entre la altura de los padres e hijos sea de tipo lineal: a mayor altura en padres mayor altura en hijos.
- En tal caso, la función que expresa la dependencia entre dichas alturas es una recta.
- Una vez determinada dicha recta podemos predecir la altura media de los hijos cuyos padres presentan una determinada estatura.

También sería interesante saber si existe alguna relación entre las ventas de una empresa y el gasto en publicidad de la misma.

- De haber relación, sería de utilidad poder predecir las ventas de una empresa para un gasto en publicidad determinado.

2. Modelo de regresión lineal

La estructura de un modelo de **regresión lineal simple** es la siguiente: $Y = \beta_0 + \beta_1 X + \varepsilon$

En esta expresión estamos admitiendo que en la variable respuesta (Y), influyen: la variable explicativa (X) y os factores no controlados que englobamos bajo el nombre de perturbación (ε).

HIPÓTESIS DEL MODELO.

1. Es deseable que estos errores aleatorios sean en media cero para cualquier valor x de X.
2. Si obtenemos lo anterior, observamos que:
 - a. La media de Y, para un valor fijo de X, varía linealmente con x.
 - b. Para un valor x se predice un valor Y dado por $Y = [E/Y=x]$, por lo que el modelo de predicción puede expresarse también como $Y = \beta_0 + \beta_1 X$.
 - c. El parámetro β_0 es la ordenada en el origen del modelo y β_1 la pendiente, que puede interpretarse como el incremento de la variable dependiente por cada incremento de una unidad de la variable independiente.
3. También observamos que los parámetros β_0 y β_1 son desconocidos y que hay que estimarlos para poder realizar predicciones.
4. La varianza de la perturbación es constante para cualquier valor de x.
5. La distribución de la perturbación es normal, de media 0 y desviación.
6. Los errores asociados a los valores de Y son independientes unos de otros.

3. Estimación de los parámetros del modelo.

Partiendo de una muestra de los valores de X e Y medidos sobre n individuos, queremos estimar valores en Y según el modelo de regresión lineal simple donde los parámetros son desconocidos.

- Debemos de encontrar, entonces, de entre todas las rectas la que mejor se ajuste a los datos observados, es decir, buscamos aquellos valores que los parámetros que hagan mínimos los errores de estimación.
- Para un valor exacto de X, obtendremos un valor de Y, de esto podemos calcular cuál es el error de estimación que viene dado por: $e_i = y_i - \hat{y}_i$ (estimada)
- Entonces se toman como estimaciones de los parámetros aquellos valores que hagan mínima la suma de los errores al cuadrado, que viene dada por:

$$SSE = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2$$

De ahí que al método de estimación lo llamemos **método de mínimos cuadrados**.

- La solución la obtenemos derivando SSE con respecto a los parámetros e igualando a 0, de ahí resultan que los estimadores son:

$$\begin{aligned}\hat{\beta}_1 &= \frac{SS_{xy}}{SS_{xx}} \\ \hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x}\end{aligned}$$

siendo:

$$\begin{aligned}SS_{xy} &= \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}, \\ SS_{xx} &= \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n \bar{x}^2 = n \sigma_x^2\end{aligned}$$

A la recta resultante se les llama **recta de regresión lineal de Y sobre X**.

- El último parámetro a estimar en el modelo es la **varianza de los errores**, a su estimador lo denominaremos **varianza residual**, que viene dada por:

$$\hat{s}_R^2 = \frac{SSE}{n-2} = \frac{\sum_{i=1}^n e_i^2}{n-2} = \frac{SS_{yy} - \hat{\beta}_1 SS_{xy}}{n-2}$$

3. Estimación de los parámetros del modelo.

EJEMPLO:

Una empresa que desea investigar el efecto de su publicidad a través de radio en el número de ventas. Con tal fin, durante cinco semanas estudia el número de ventas (Y) según el número de días a la semana (X) que se da publicidad a la empresa en la radio. Los resultados se recogen en la siguiente tabla. Determinar la recta de regresión.

SEMANA	Nº DÍAS PUBLICIDAD (X)	Nº DE VENTAS (Y)
1	1	1
2	2	1
3	3	2
4	4	2
5	5	4

4. Inferencias sobre el coeficiente de regresión.

Los estimadores dependen de la muestra seleccionada, por lo que estos son variables aleatorias y presentarán una distribución de probabilidad. Estas funciones de probabilidad de los estimadores pueden utilizarse para construir intervalos de confianza o contrastes sobre los parámetros del modelo de regresión.

Si volvemos al inicio del tema, nos planteamos decidir si el efecto de la variable independiente es o no significativo para la variable dependiente, esto equivale a contrastar si el coeficiente independiente es o no significativamente distinto de cero.

En resumen, planteamos los siguientes contrastes para el parámetro independiente:

Tipo prueba	Unilateral izqda	Bilateral	Unilateral derecha
Contraste	$H_0 : \beta_1 = b_1$ $H_1 : \beta_1 < b_1$	$H_0 : \beta_1 = b_1$ $H_1 : \beta_1 \neq b_1$	$H_0 : \beta_1 = b_1$ $H_1 : \beta_1 > b_1$
Est.contr.	$t = \frac{\hat{\beta}_1 - b_1}{\sqrt{\hat{s}_R^2 / SS_{xx}}}, \text{ con } \hat{s}_R^2 = \frac{SS_{yy} - \hat{\beta}_1 SS_{xy}}{n - 2}$		
R. H_0	$t < t_{\alpha, n-2}$	$ t > t_{1-\alpha/2, n-2}$	$t > t_{1-\alpha, n-2}$

Para el ejemplo anterior, contrastar si el número de días de publicidad en radio tiene efecto significativo sobre el nº de ventas con un nivel de significación del 5%.

5. El coeficiente de correlación lineal y el coeficiente de determinación.

Una vez que hemos determinado los parámetros y hemos visto si la variable independiente tiene efecto o no en el modelo de regresión, pasamos a medir la **bondad de ajuste** de la recta de regresión a los datos observados y **cuantificar** al mismo tiempo el grado de asociación lineal existente entre las variables en cuestión.

A mejor ajuste, mejores serán las predicciones realizadas con el modelo. La evaluación global de una recta de regresión podría hacerse mediante la varianza residual, que como sabemos es un índice de la precisión del modelo, sin embargo, esta medida no es útil para comparar rectas de regresión de variables distintas o comparar el grado de asociación lineal entre distintos pares de variables, ya que depende de las unidades de medida de las variables.

Como solución a este inconveniente, **para medir la asociación lineal** de dos variables X e Y, se utiliza una medida adimensional denominada **coeficiente de regresión lineal**, este coeficiente viene dado por:

$$r = \frac{E[(X - E(X))(Y - E(Y))]}{\sqrt{VAR(X)VAR(Y)}} = \frac{\sqrt{VAR(X)}}{\sqrt{VAR(Y)}}\beta_1$$

y su estimación a partir de datos de una muestra viene dada por:

$$\hat{r} = \frac{SS_{xy}}{\sqrt{SS_{xx}SS_{yy}}} = \frac{\sqrt{SS_{xx}}}{\sqrt{SS_{yy}}}\hat{\beta}_1$$

PROPIEDADES:

- Toma valores entre -1 y 1.
- Un valor cercano o igual a 0 indica respectivamente poca o ninguna relación lineal entre las variables.
- Cuanto más se acerque el valor absoluto a 1 mayor será el grado de asociación lineal entre las variables. Un coeficiente igual a 1 en valor absoluto indica una dependencia lineal exacta entre las variables.
- Un coeficiente positivo indica asociación lineal positiva, es decir, tienden a variar en el mismo sentido.
- Un coeficiente negativo indica asociación lineal negativa, es decir, tienden a variar en sentido opuesto.

OBSERVACIONES:

- Si la variable independiente es 0, entonces el coeficiente de regresión lineal es 0, en cuyo caso hay ausencia de linealidad.
- Contrastar si el coeficiente de correlación lineal es significativamente distinto de 0 sería equivalente a contrastar si el parámetro independiente es significativamente distinto de 0.
- El coeficiente de correlación lineal puede interpretarse como una medida de la bondad del ajuste del modelo lineal, concretamente, un valor del coeficiente igual a 1 o -1 indica dependencia lineal exacta, en cuyo caso el ajuste es perfecto.

5. El coeficiente de correlación lineal y el coeficiente de determinación.

No obstante, para poder cuantificar la bondad del ajuste de un modelo, ya sea lineal o no, se utiliza una medida que se denomina **coeficiente de determinación (R^2)**, este coeficiente es la proporción de la variabilidad de la variable Y que queda explicada por el modelo de entre toda la presente, y cuya expresión es:

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{SSE}{SS_{yy}},$$

que en el modelo de **regresión lineal** coincide con el cuadrado del coeficiente de determinación.

PROPIEDADES:

- Toma valores entre 0 y 1, y cuanto más se aproxime a 1 mejor será el ajuste del modelo lineal, y por lo tanto mayor fiabilidad de las predicciones que con él realicemos.
- Nótese que si el coeficiente de correlación lineal r es igual a 1 o -1. entonces $R^2=1$ y por tanto el ajuste lineal es perfecto.

EJEMPLO:

En el ejemplo anterior, obtenemos que:

$$r = 0.90 \text{ y } R^2 = 0.82.$$

Esto nos indica que el grado de asociación lineal entre las variables es alto, y concretamente el 82% de la variación total de los valores del nº de ventas pueden ser explicados mediante la recta de regresión ajustada.

6. Predicción a partir del modelo.

Recordamos que en el modelo ajustado de la recta de regresión,

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

y, por otro lado,

$$E[Y/X = x] = \beta_0 + \beta_1 x,$$

luego $\hat{y}$ puede interpretarse de dos formas:

1. Como predicción del valor que tomará Y cuando $X = x$.
2. Como estimación del valor medio en Y para el valor $X = x$, es decir, $E[Y/X = x]$.

Ambas cantidades están sujetas a incertidumbre, que será tanto mayor cuanto peor sea el ajuste realizado mediante la recta de regresión, por lo que establecemos un intervalo de confianza para estas cantidades.

$$E[Y/X = x] \in \left[\hat{y} \pm t_{1-\alpha/2, n-2} s_R \sqrt{\frac{1}{n} + \frac{(x - \bar{x})^2}{SS_{xx}}} \right]$$

EJEMPLO:

Para los datos del ejemplo anteriormente vistos:

- a) Predecir el nº de ventas semanales para 6 días de publicidad de radio.
- b) ¿En qué medida son fiables las predicciones realizadas con la recta de regresión ajustada?
- c) Determinar un intervalo al 95% de confianza para el nº medio de ventas si se hace 6 días de publicidad en radio.

7. Diagnóstico del modelo.

Análisis residual. Conjunto de procedimientos gráficos y analíticos que conducen a la comprobación de las hipótesis de partida del modelo.

Hipótesis.

- **Aleatoriedad.**
 - Procedimientos gráficos: Gráfico de residuos frente al número de fila.
 - Procedimiento analítico: Test de Rachas
- **Independencia.**
 - Procedimientos gráficos: Gráfico de residuos frente al número de fila.
- **Homocedasticidad.**
 - Procedimientos gráficos: Gráficos de residuos frente a valores ajustados y gráficos de residuos frente a otras variables.
 - Procedimiento analítico: Test de Bartlett.
- **Normalidad.**
 - Procedimientos gráficos : Histograma, Gráfico QQ-plot y Gráfico de probabilidad normal.
 - Procedimientos analíticos: Contraste de Shapiro-Wilk y Contraste de Kolmogorov-Smirnov.